

Universidade do Minho
Escola de Engenharia

Bombedia, uma ferramenta para detecção de Notícias que despoletem Controvérsia

Laboratórios de Engenharia Informática
MEI - 4^o Ano - 2^o Semestre
Grupo 95

Constança Elias (PG42820)
Jorge Brandão Gonçalves (PG42838)
Maria Araújo Barbosa (PG42844)
Pedro Pinheiro (PG44421)

20 de junho de 2021

Resumo

Este trabalho foi desenvolvido no âmbito da unidade curricular de Laboratórios de Engenharia Informática e tem como principal objetivo contribuir para análise e previsão da capacidade de *Computer-mediated communication* (CMC), em português, despoletarem reações por partes dos leitores e, mais concretamente, controvérsia ou comentários negativos. Trata-se, pois, da criação de uma ferramenta capaz de prever a possível controvérsia de um *post*, desenvolvendo-se, para tal, um modelo de *Machine Learning* com a capacidade de fazer tal previsão. Para o treino deste modelo será usado um *dataset* do *Twitter* e para validação dos resultados obtidos serão utilizados textos de jornais portugueses, *Público* e *Sol*.

Área de Aplicação: Análise de Sentimentos, Processamento de Linguagens, *Machine Learning*

Agradecimentos

Este trabalho não seria possível sem a proposta do professor Pedro Rangel Henriques e da professora Cristiana Araújo, a quem agradecemos a ajuda e o entusiasmo com que nos cativaram para o projecto e aceitaram o pedido para serem os nossos orientadores. Gostaríamos também de prestar o nosso agradecimento ao Engenheiro Aragão, do grupo de técnicos do Departamento de Informática, pela disponibilidade imediata para ajudar em todos os problemas técnicos que tivemos com o servidor e pela sempre rápida resposta aos pedidos feitos. É nosso dever agradecer também ao Dr. Ricardo Martins por todas as dicas e conselhos prestados de forma a que o trabalho pudesse tomar o bom rumo que levou.

Conteúdo

1	Introdução	5
1.1	Contextualização	5
1.2	Motivação	5
1.3	Objetivos	6
1.4	Estrutura do Relatório	6
2	Estado de Arte	7
2.1	<i>Computer-Mediated Communication (CMC)</i>	7
2.2	Análise de sentimentos em CMC	7
2.3	Previsão do número de comentários em CMC	7
2.4	Análise da controvérsia de CMC em português	8
3	Análise e especificação do problema	9
4	Bombedia – Arquitectura	11
5	Recolha de dados – <i>Dataset</i>	13
5.1	Fonte de dados	13
5.2	Obtenção dos dados	13
5.2.1	<i>Twitter API</i>	14
5.2.2	Ferramenta <i>Twint</i>	14
5.3	Classificação	15
5.3.1	NRC Emotion Lexicon	15
5.3.2	<i>Spacy</i> - Lematização e Tokenização	15
5.4	Otimização da classificação do <i>dataset</i>	16
5.5	Balanceamento do <i>dataset</i>	16
6	Análise e preparação dos dados	18
7	Modelos	20
7.1	LSTM	20
7.2	GRU	20
7.3	CNN	21
7.4	<i>Naive Bayes</i>	21
7.5	<i>Logistic Regression</i>	21

8	Resultados obtidos	22
8.1	Modelos	22
8.2	Processamento dos jornais	24
8.3	Validação dos resultados com o NetAC	24
9	Bombastic Media – <i>Web App</i>	27
9.1	Requisitos da <i>Web App</i>	27
9.2	Público Alvo (Utilizadores)	28
9.3	Arquitetura	28
9.3.1	<i>App Server</i>	29
9.3.2	<i>API Server</i>	29
9.3.3	<i>Authentication Server</i>	29
9.3.4	<i>TensorFlow Serving</i>	29
9.3.5	Servidor <i>Flask</i>	30
9.4	Aplicação Final	30
9.4.1	Analisador	30
9.4.2	Analisador por <i>URL</i>	32
9.5	Pesquisa por Palavras Controversas	32
9.6	Temas Quentes	33
9.6.1	Temas mais procurados	33
9.6.2	Análise de Temas ao longo do tempo	33
9.7	Manter a classificação atualizada	34
10	Alternativas, Decisões e Problemas de Implementação	36
10.1	Decisões	36
10.1.1	Dataset	36
10.1.2	Otimização da classificação do <i>dataset</i>	36
10.1.3	Ferramentas	37
10.1.4	Modelos de <i>Machine Learning</i>	37
10.2	Problemas de Implementação	37
10.2.1	<i>Encoding</i>	37
11	Conclusão	38
A	<i>Corpus</i> de Palavras Controversas	43
B	Comparação NetAc vs Bombedia	44

Lista de Figuras

4.1	Arquitetura do projeto.	12
5.1	Exemplos de <i>tweets</i> mal classificados no <i>dataset</i> inicial	14
5.2	Pipeline para obtenção do dataset.	16
5.3	Distribuição da classificação do dataset.	17
6.1	Palavras mais frequentes nos <i>posts</i> classificados como Negativos	19
8.1	Resultados de treino do modelo LSTM ao longo de 30 epochs.	23
8.2	Resultados de treino do modelo GRU ao longo de 30 epochs.	23
8.3	Matriz de confusão obtida para o modelo de regressão linear.	23
8.4	Tabela síntese com os resultados obtidos para o jornal Sol	25
8.5	Validação dos resultados obtidos pela ferramenta NetAc.	26
9.1	Arquitetura da Web App Bombedia.	29
9.2	<i>Pipeline</i> otimizada da classificação de <i>posts</i>	31
9.3	Analisador de <i>posts</i>	31
9.4	Exemplo de um resultado fornecido pelo analisador	31
9.5	Funcionalidade de procura por palavras controversas no Bombedia	32
9.6	Apresentação dos 6 temas mais procurados no <i>Google</i> no dia 16 de junho de 2021	33
9.7	Índice de pesquisas para o termo "Coronavírus" ao longo dos últimos cinco anos	34
9.8	<i>Pipeline</i> do processo de atualização do <i>dataset</i>	35

Capítulo 1

Introdução

1.1 Contextualização

O uso de redes sociais e da comunicação *online* têm vindo a crescer exponencialmente ao longo dos últimos anos. Este facto depoleta a atenção de várias indústrias para as plataformas *online* que proporcionam esta comunicação, como é o caso dos jornais, por exemplo. Consequentemente, a interacção dos utilizadores com notícias *online* tem vindo a adquirir maior importância e vários produtores de meios de comunicação social e conteúdo *online* competem pela atenção dos utilizadores. A presença de notícias sobre temas controversos pode gerar reacções nos utilizadores, levando-os a utilizar a secção de comentários (ou até mesmo as redes sociais) para difundir comportamentos negativos que sejam prejudiciais ao ambiente jornalístico ou outros ambientes de comunicação, onde tais comentários são acessíveis a todos os utilizadores dessas plataformas. [1]. Desta forma, pode surgir um discurso tóxico e ofensivo ou, por outro lado, manifestações a favorecer e a apoiar o que foi dito.

Tendo este contexto por base, foi-nos feita esta proposta de trabalho pelos coordenadores do projeto, no âmbito da unidade curricular de Laboratórios de Engenharia Informática. Surgiu da perceção da importância e do impacto que a criação de uma ferramenta capaz de analisar a controvérsia que *posts* e notícias *online*, poderá ter em áreas não só do processamento de linguagens e da Inteligência Artificial como também em áreas sociais e linguísticas.

Pretende-se então, com este projeto, analisar textos de artigos ou *posts* (concretamente em língua portuguesa) para avaliar a sua potencialidade para despoletar controvérsia, e ainda, procurar estabelecer uma relação entre a existência de discurso pejorativo/grosseiro nos comentários e o sentimento gerado pelo *post* (negativo, positivo ou neutro).

1.2 Motivação

A principal motivação que deu origem ao desenvolvimento deste projeto foi a importância da contribuição deste estudo para a análise que existe nesta área em português. Uma vez que esta é bastante escassa quando comparada por exemplo com o trabalho já desenvolvido para a língua inglesa, pretende-se seguir uma abordagem nova, partindo do que já está a ser feito, para a língua portuguesa.

1.3 Objetivos

Partindo da motivação acima descrita, pretende-se prever a quantidade de comentários que um conteúdo de *media online* irá gerar ainda antes de ser publicado, ou seja, saber se a notícia será controversa e implicará o movimento das "massas". Para tal avaliação, pretende-se ter por base o tipo de palavras presentes no texto (positivas, negativas ou neutras). Numa fase posterior, pretende-se ainda saber se a reação despoletada será maioritariamente positiva ou negativa e estabelecer uma relação com o tipo de comentários gerados, com o auxílio da ferramenta NetAC (*NetLang Analyser and Classifier*).

1.4 Estrutura do Relatório

Este relatório divide-se em onze capítulos.

O capítulo 1 faz uma breve introdução ao problema e expõe a motivação e objetivos do trabalho a desenvolver.

O capítulo 2 consiste na análise do estado de arte no que se refere à previsão de comentários e reações que um *post* ou uma notícia *online* poderão despoletar.

O capítulo 3 analisa em detalhe a contribuição deste projeto para a área bem como os principais requisitos do mesmo.

A arquitetura do **Bombedia** é explicada no capítulo 4, bem como a *pipeline* de desenvolvimento do projeto.

Os capítulos 5 e 6 apresentam, respectivamente, como foi obtido o *dataset* para treino dos modelos de *Machine Learning* desenvolvidos e as técnicas de análise e preparação de dados aplicadas aos *posts* selecionados.

Os capítulos 7 e 8 explicam, respetivamente, os modelos desenvolvidos e os resultados por eles obtidos. Neste último capítulo é ainda efetuada uma comparação dos resultados obtidos pelo **Bombedia** com os resultados obtidos pelo *NetAC*.

A plataforma *web* desenvolvida, **Bombedia**, é detalhadamente apresentada no capítulo 9.

No capítulo 10, é feita uma análise resumida das decisões que foram sendo tomadas ao longo do desenvolvimento do projeto bem como dos problemas encontrados.

Por fim, no capítulo 11, é feita uma breve síntese do trabalho realizado, apresentando as principais conclusões do mesmo.

Capítulo 2

Estado de Arte

Ao longo desta secção serão abordados alguns conceitos importantes para a compreensão deste trabalho e ainda vários projetos que têm sido desenvolvidos na área de estudo do presente trabalho.

2.1 *Computer-Mediated Communication (CMC)*

De acordo com [2], o termo *Computer-Mediated Communication (CMC)* pode ser definido como “qualquer tipo comunicação humana que envolva um ou mais aparelhos eletrónicos”. Embora tradicionalmente o termo se tenha referido às comunicações que ocorriam e ocorrem através de formatos mediados por computador (por exemplo mensagens instantâneas, correio electrónico, *chat rooms*, *online forums*, redes sociais), este também tem sido aplicado a outras formas de interação baseada em texto, tais como mensagens de texto (que não envolvem a *internet*) [3].

Vários estudos têm sido feitos para averiguar os diversos campos que envolvem CMC, desde a análise de como os seres humanos utilizam “computadores” (ou meios digitais) para gerir e formar relações interpessoais [4] [5] ao estudo das características paralinguísticas utilizadas neste contexto, tais como *emoticons*, [6] regras pragmáticas, como a tomada de decisões [7] ou a análise sequencial, e organização da conversa [8].

2.2 Análise de sentimentos em CMC

Várias investigações têm sido feitas ao longo dos anos no que se refere à análise de sentimentos e avaliação e previsão das reações que os CMC provocam aos leitores. No entanto, nenhum destes estudos se foca concretamente na língua portuguesa. Recentemente, em 2020, *Branz et al.* [9] realizaram um estudo relacionado com a análise de sentimentos em dados da rede social *Twitter*. Tem-se vindo a estudar como diversas *features* afetam a classificação dos *tweets*. [10] [11]

2.3 ~~Previsão do número de comentários em CMC~~

Após a leitura de algum artigo ou notícia *online*, alguns leitores publicam a sua opinião no próprio site onde o artigo foi publicado ou em redes sociais, como o *Twitter*. Estas respostas têm muito conteúdo emocional [12] que muitas vezes vem associado ao conteúdo da notícia ou à forma como a mesma foi escrita. Em 2009, foi feito

um estudo com foco na língua holandesa [22], com objetivo de conseguir prever a quantidade de comentários que uma notícia poderá gerar com base em várias *features*, nomeadamente características semânticas e metadados, como a hora, o autor, entre outros. Outro estudo, de 2019, [12] fez uma previsão das reações emocionais que os utilizadores do *Twitter* expressam depois de ler determinado artigo, utilizando, para isso, uma estratégia de *multitarget*. Para este estudo é utilizado um *Corpus* em língua espanhola. Mais recentemente, em 2020, foi feita uma análise a várias notícias com o objetivo de prever o número total de comentários que uma notícia *online* pode obter, com base na análise de várias *features* (como o tema, o título, os comentários) chegando à conclusão que os primeiros comentários têm muito impacto e definem a existência de reação por parte dos leitores. [13]. Outro estudo semelhante foi feito, também em 2020 para avaliar a toxicidade de notícias, incluindo algumas portuguesas [1].

2.4 Análise da controvérsia de CMC em português

A análise da controvérsia e carga emocional associada a CMC em língua portuguesa é muito escassa na literatura. Neste sentido, este projeto ~~é inovador~~ na medida em que faz uma **análise semântica** do texto para criar um modelo que seja capaz de prever se um determinado *post online* irá gerar controvérsia. Sendo a língua portuguesa muito rica em termos de vocabulário e expressões próprias, este processo torna-se desafiante e um pouco complexo. No entanto, tirando partido de bibliotecas já existentes e recomendadas noutros estudos, este trabalho pretende obter uma classificação binária em termos do conteúdo da notícia: controversa ou não controversa. A classificação como "controversa" pode ser subdividida em duas categorias, "positiva" ou "negativa", indicando a carga emocional associada à notícia. **Uma frase é considerada controversa se no pré-processamento a frase em questão for considerada como tendo o conteúdo positivo ou negativo, que nos indica a possibilidade de vir a despoletar comentários, quer positivos quer negativos.**

Vários trabalhos realizados neste âmbito foram feitos para português do Brasil. [14] [15] [16].

Capítulo 3

Análise e especificação do problema

Partindo da avaliação do estado de arte no que se refere à análise de sentimentos e previsão da controvérsia que a comunicação mediada por tecnologias pode despoletar nos leitores, pretendemos desenvolver, neste capítulo, a contribuição que o problema proposto irá trazer para as áreas em estudo.

Como já foi referido, pretende-se estudar a capacidade de um *post* em português gerar controvérsia no público alvo do mesmo. Após uma revisão da literatura, foi constatado que muito trabalho de estudo nesta área tem sido feito para outras línguas, mas no que se refere à língua portuguesa, existe uma lacuna. Encontram-se, no entanto, vários estudos feitos para português do Brasil, como foi referenciado no capítulo anterior.

Da análise do problema, surgiu então a seguinte proposta de trabalho:

- Ter por base o *dataset* para análise de sentimentos do *Twitter* para classificação da capacidade dos *posts* despoletarem controvérsia;
- Utilizar modelos de *Machine Learning* para criar uma ferramenta capaz de identificar, a partir do conteúdo de um *post*, o tipo de reações que este poderá provocar aos leitores;
- Dispor de um *Corpus* de jornais portugueses, fornecidos pelo *NetLang*, para validação dos resultados obtidos;
- Submeter o *Corpus* de jornais à ferramenta *NetAc* (*NetLang Analyzer and Classifier*)¹, que classifica os comentários de um *post* de acordo com o tipo de discurso de ódio presente, e estabelecer uma relação entre estes resultados e os resultados produzidos pela ferramenta desenvolvida neste projeto;
- Desenvolver uma aplicação *web* que integre as ferramentas desenvolvidas ao longo do projeto, permitindo a diversos utilizadores obter uma classificação de qualquer tipo de CMC.

O foco deste projeto será sobretudo notícias, embora facilmente seja utilizada para a análise de qualquer tipo de texto *online* que envolva a comunicação ou interação entre

¹<http://netlang-corpus.ilch.uminho.pt:10100/>

vários utilizadores. Pretende-se, para além disto, permitir aos utilizadores guardarem um histórico dos ficheiros analisados para posterior análise.

Tenciona-se ainda fazer uma comparação dos resultados obtidos neste estudo com os resultados que são fornecidos para ferramenta **NetAC**, que permite classificar os comentários de uma notícia ou outro tipo de CMC, indicando a percentagem de *hate speech* presente nesses comentários, bem como o tipo de discurso de ódio de que se trata (racial, sexual, religioso, etc.).

Capítulo 4

Bombedia – Arquitectura

Neste capítulo pretende-se explicar, ~~por alto~~, a arquitetura desenvolvida para o Bombedia de forma a resolver o problema proposto. As várias fases que compõem a arquitetura do sistema serão analisadas mais em detalhe ao longo dos próximos capítulos. A arquitetura desta solução encontra-se representada, de forma sucinta, ~~no esquema~~. 4.1. Inicialmente, começa-se por extrair dados directamente do *Twitter* que são submetidos a um processo de tratamento com o objetivo de os adaptar de acordo com os requisitos do enunciado. Deste modo, com o auxílio de um dicionário para palavras em português, *NRC Lexicon*, os *tweets* extraídos são classificados e guardados num ficheiro em formato *csv*. Segue-se, depois, uma fase de processamento, cujo objectivo é preparar os dados para serem submetidos aos modelos de *Machine Learning* desenvolvidos.

Tendo definido vários modelos, sucede-se uma análise dos resultados obtidos com o intuito de seleccionar o modelo com as melhores características. Tendo o modelo final seleccionado, procede-se à sua validação através da comparação dos resultados obtidos pelo *NetAC* com os dados obtidos pela plataforma Bombedia. Finalmente, integra-se o modelo preditivo na interface de consulta desenvolvida, *Bombedia*, na qual é possível o utilizador analisar a controvérsia de *posts* à sua escolha e obter resultados.

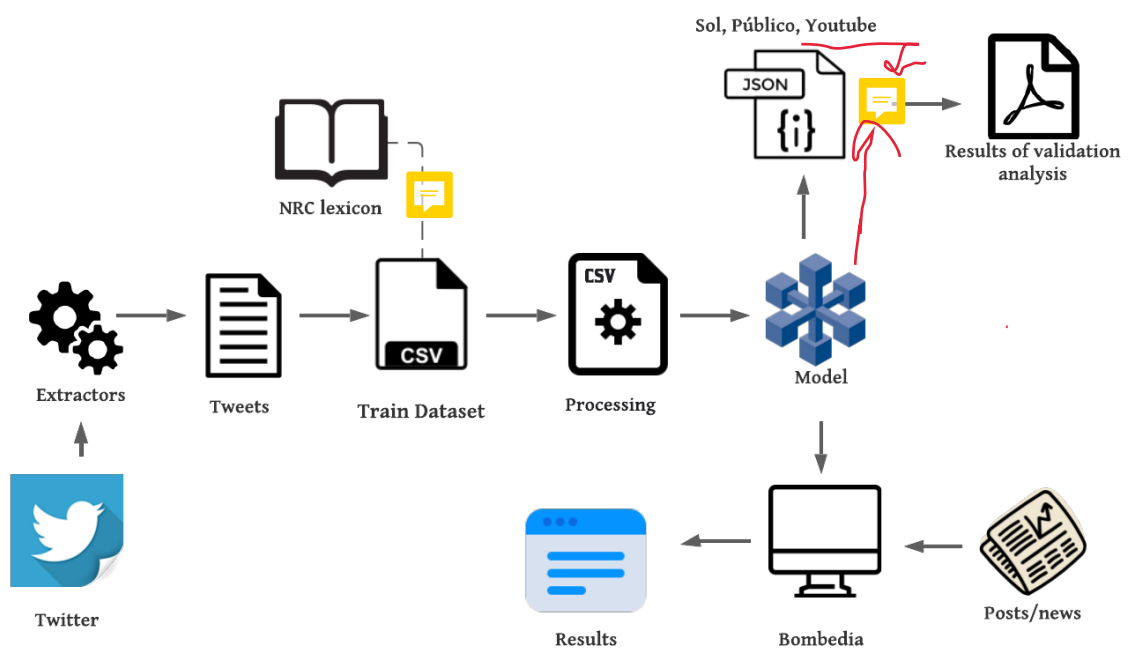


Figura 4.1: Arquitetura do projeto.



Capítulo 5

Recolha de dados – *Dataset*

Nesta secção será explicado em detalhe o processo de obtenção dos dados para a criação de um *dataset* para treino e teste dos modelos de *Machine Learning* que se pretendiam desenvolver.

5.1 Fonte de dados

Sabe-se que as redes sociais têm-se tornado uma importante plataforma de comunicação onde os utilizadores expressam opiniões e sentimento em conversas ou mensagens. [17]. Uma plataforma popular nos dias de hoje é o *Twitter* que possui mais de 330 milhões de utilizadores, que partilham cerca de 500 milhões de *tweets* por dia associados a diversos contextos e possuindo diferentes polaridades [18] [19]. Este foi o ponto de partida que levou o grupo a escolher o *Twitter* como fonte de dados. Para além desta razão, vários outros motivos levaram a esta decisão:

- ser uma rede social bastante extensa, com utilizadores de diversas faixas etárias, culturas e condições sociais, contendo, por isso todo o tipo de comentários e *posts*, sobre temas muito variados da atualidade, que permitem obter um *dataset* diversificado [20];
- ser uma fonte para obtenção de *datasets* muito utilizada na literatura, no que se refere a análise de sentimentos e comportamentos dos utilizadores em redes sociais e CMC (como foi analisado no capítulo 2);
- ter sido utilizada anteriormente por um elemento do grupo para o desenvolvimento de um trabalho sobre análise de sentimentos, tendo mostrado resultados bastante positivos;
- ser uma fonte acessível e rápida para recolha de dados de CMC.

5.2 Obtenção dos dados

Tendo escolhido a fonte de dados foi necessário proceder à recolha dos mesmos. O *dataset* pretendido deveria ter, no mínimo, duas colunas: *tweets* e *classificação*. Esta última coluna deveria indicar o sentimento associado ao *tweet*, que poderia ser um de três: **Positivo**, **Negativo** ou **Neutro**.

Inicialmente, utilizou-se um *dataset* neste formato que se encontra disponível *on-line*¹. No entanto, depressa se percebeu que este se encontrava muito mal classificado. Foi detetado, por exemplo, que os *emojis* presentes nos *tweets* tinham um grande peso na classificação dos mesmos induzindo em graves erros. A figura 5.1 apresenta exemplos de alguns *tweets* mal classificados nesse *dataset* (que parecem ser classificados tendo em conta apenas os *emojis* que aparecem no final).

```
Positive => Feliz dias das crianças pra vcs seus lixos :)

Positive => Queridos vizinhos, AGRADEÇO QUE PAREM DE FAZER OBRAS PORQUE NÃO VOS AGUENTO MAIS CARALH
O, atentamente a vizinha do último andar :)

Positive => @requiaopmdb alguns como eu optaram por seguir vc pra ver as aberrações que vc posta ,
as mentiras e promessas falsas , o povo deu a resposta pra vc nas urnas :) por isso não foi reeleito.
Esperta foi a Gleisi Hoffman sabendo que seria estimada de governadora e senadora concorreu a deputad
a

Positive => independente de gostar apenas do que o fp produz, tenha respeito à pessoa que trabalha
nos sons que viralizam no youtube, nas festinhas e nos bailes. hipocrisia master escutar um negro fav
elado e votar num candidato que tem aversão a minorias sociais :-)
```

Figura 5.1: Exemplos de *tweets* mal classificados no *dataset* inicial

Para além disso, este *dataset* estava em brasileiro, o que para o nosso projeto não era benéfico, uma vez que há palavras substancialmente diferentes e/ou com outro significado às palavras equivalentes em língua portuguesa. A adicionar a esse facto, os temas que podem ser considerados controversos no Brasil (nomeadamente, assuntos relacionados com figuras públicas concretas, etc..) podem não o ser em Portugal. Tendo estes dois aspetos em conta e como o foco da análise era a língua portuguesa, o grupo decidiu procurar outro *dataset*. Rapidamente se percebeu que não existia um *dataset* em língua portuguesa já classificado e disponível na *web* pelo que o grupo chegou à conclusão que deveria ser incluída mais uma etapa no projeto: a construção de *dataset* adequado ao objeto de estudo, passando assim pelas fases de extração, normalização e limpeza dos dados, bem como a posterior classificação.

5.2.1 *Twitter API*

De forma a proceder à obtenção de novos dados, optou-se por recolher os dados recorrendo diretamente à *API* do *Twitter*. Foi pedida a chave de acesso mas não houve resposta nas duas semanas que se seguiram pelo que foi necessário pensar numa alternativa.

5.2.2 Ferramenta *Twint*

Após alguma pesquisa, descobriu-se a existência de uma ferramenta *open source*, *Twint*², que permite, de forma simples, extrair partilhas realizadas no *Twitter*, sem qualquer limitação. Podem ainda ser aplicados filtros de forma a obter um conjunto específico de *tweets* que satisfaçam o pretendido.

Com o objetivo de obter uma distribuição equitativa de dados de todo o país, foram recolhidas mensagens emitidas nas principais cidades portuguesas , até um raio de 30

¹<https://www.kaggle.com/leonardoassis/portuguese-tweets-nltk-and-sklearn>

²<https://github.com/twintproject/twint>

kms de cada cidade. Assim, foi possível garantir que os *tweets* extraídos eram colocados apenas por utilizadores que se encontrassem em território nacional. Optou-se também por fazer a extração de *tweets* escritos a partir de fevereiro de 2021, data em que se iniciou este projeto, de modo a obter comentários mais recentes e atuais. Foi obtido então o primeiro *dataset* com 100000 entradas.

5.3 Classificação


Depois de obter o *dataset*, o passo seguinte consistiu em analisar as emoções associadas a cada *tweet* de modo a perceber se o mesmo era controverso ou não.

Para a classificação das várias entradas, desenvolveu-se um pequeno *script* em *Python* que lê cada texto associado ao *tweet* e classifica-o tendo em conta uma lista de palavras classificadas como positivas, negativas ou neutras. Esta lista de palavras corresponde à versão portuguesa do *Corpus* disponibilizado pelo *NRC Word-Emotion Association Lexicon* (ou *EmoLex*).

5.3.1 NRC Emotion Lexicon

O NRC Emotion Lexicon consiste num dicionário de palavras em inglês e a sua relação com uma lista de oito emoções. Estas emoções são: (*anger, fear, anticipation, trust, surprise, sadness, joy, and disgust*). Tem também associados dois sentimentos: positivo e negativo. Esta classificação das palavras foi feita por *crowdsourcing*. Para a classificação utilizámos a tradução disponível para português³.

5.3.2 *Spacy* - Lematização e Tokenização

Para poder aplicar o NRC às várias entradas do *dataset*, foi necessário efetuar um processo de tokenização e de lematização a cada uma dessas entradas. Utilizando o módulo *spacy*⁴, para português, foi possível automatizar o processo de tokenização das frases. Para a lematização dos vários *tokens* obtidos (processo de deflexionar uma palavra para determinar o seu lema) foi definida uma função que extrai o lema a partir dos *tokens* gerados pelo módulo *spacy*. A escolha da utilização deste módulo deveu-se ao facto de o mesmo permitir, de forma simples, efetuar os dois processos referidos para a língua portuguesa. 

O *dataset* final ficou então composto por dois campos: o texto associado ao *tweet* e a sua classificação. O esquema 5.2 resume o *pipeline* seguido para a obtenção do *dataset* classificado.

³obtida de <https://saifmohammad.com/WebPages/AccessResource.htm>

⁴<https://spacy.io/>

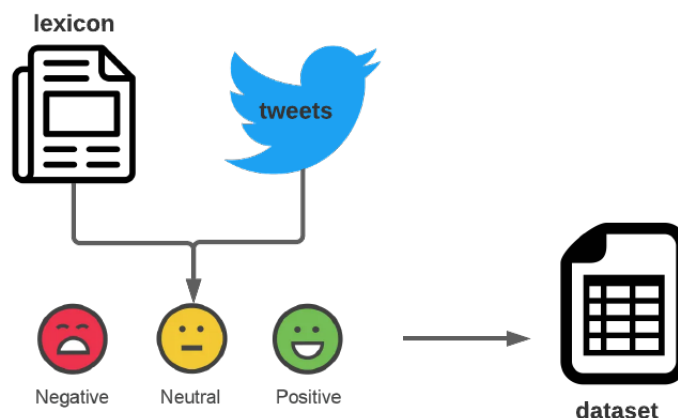


Figura 5.2: Pipeline para obtenção do dataset.

5.4 Otimização da classificação do *dataset*

No fim da classificação feita pelo NRC, foi feita uma última fase de processamento em que se classificaram palavras que, embora fossem neutras, pudessem causar controvérsia, sendo estas palavras classificadas como positivas ou negativas. Para tal foi criado um *corpus* onde se encontram palavras que poderão gerar controvérsias em determinados contextos. Exemplos destas palavras são: racismo, transgênero, entre outras. O *corpus* completo pode ser consultado no anexo A. Esta fase contribuiu para uma melhor classificação dos *tweets* do *dataset* em relação à capacidade de despoletar controvérsia e não só uma simples análise de sentimentos.

5.5 Balanceamento do *dataset*

Com a consulta de algumas informações relativas ao *dataset* e a visualização de alguns gráficos, foi possível verificar que o *dataset* se encontrava bastante desbalanceado, apresentando mais de 55 % de *tweets* classificados como neutros, 32% como positivos e apenas 13 % como negativos. Assim sendo, o passo seguinte passou por balancear o *dataset*. Para isso foram extraídos *tweets* associados a temas polémicos aquando da realização do trabalho e que se sabia que iriam gerar controvérsia, isto é, comentários negativos. Estes foram os temas utilizados para o efeito: "Cristina Ferreira", "bbtvi", "Sócrates", "Pinto da costa", "Desconfinamento".

Com esta extração foi possível expandir o *dataset*, aumentando o número de *tweets* associados a uma reação negativa. Aplicando o *script* de classificação definido e explicado anteriormente, foram adicionados os novos *tweets* classificados ao *dataset* tornando-o equilibrado. O gráfico 5.3 permite visualizar esse equilíbrio, mostrando que o *dataset* apresenta cerca de 60 mil entradas para cada um dos três sentimentos, ficando com um total de 186000 entradas.




Figura 5.3: Distribuição da classificação do dataset.

Capítulo 6

Análise e preparação dos dados

Após concluído o processo de tratamento do *dataset*, verificando que não existiam valores em falta e que este se encontrava balanceado e **corretamente classificado**, procedeu-se à análise dos componentes dos textos dos *tweets* que seriam realmente importantes para o treino dos modelos definidos numa fase posterior. Ao longo deste capítulo será explicado em detalhe o processo de preparação dos dados. As decisões tomadas tiveram em vista a obtenção de uma melhor *performance* de classificação do modelo. Assim, nesta etapa destaca-se a realização dos seguintes métodos:

- Conversão de todas as palavras para minúsculas;
- Remoção das *stopWords* (palavras que não adicionam qualquer significado à frase);
- Remoção dos sinais de pontuação, caracteres especiais, *links* e *hashtags*;
- Conversão das palavras para um formato *standard* (transformar as abreviaturas nas suas palavras originais).

Todos estes passos foram feitos de modo a minimizar as palavras que eram classificadas numa frase, visto que não é necessário classificar certas palavras que não adicionam significado à frase (*stopWords*). Foram retirados também os caracteres especiais desnecessários à classificação, através de expressões regulares e foram removidos sinais de pontuação e *emojis* recorrendo ao módulo `gensim`¹ do *Python*. Por fim, trocaram-se abreviaturas pelas palavras corretas originais (como por exemplo "tb" para também), de modo a poderem ser corretamente classificadas.

A figura 6.1 apresenta as palavras mais frequentes que foram encontradas nos *tweets* classificados como negativos. Os temas que aparecem em grande estão relacionados com as datas em que foram recolhidos os *tweets*.

¹<https://pypi.org/project/gensim/>

Capítulo 7

Modelos

Concluída a fase de processamento de dados, procedeu-se ao desenvolvimento do modelo preditivo. Como foi referido inicialmente, decidiu-se recorrer a Inteligência Artificial para esta etapa.

Neste capítulo, será apresentado o trabalho desenvolvido para a obtenção de um modelo de *Machine Learning* (ML) capaz de prever a capacidade que uma notícia tem de gerar controvérsia. Com o objectivo de explorar várias abordagens no que se refere ao desenvolvimento de modelos de ML e perceber aquela que se mostrava mais vantajosa para o estudo em questão, desenvolveram-se vários modelos que serão explicados de seguida.

7.1 LSTM

O modelo LSTM (*Long Short Term Memory*) é muito usado em ML, no campo de *Deep Learning*. É do tipo de RNN (*Recurrent Neural Networks*) e possui uma grande capacidade de aprender dependências a longo prazo [25]. Após a análise do estado de arte, foi fácil perceber que este é um dos modelos mais utilizado no âmbito de análise e processamento de linguagens e por isso decidiu-se testar a sua implementação.

A LSTM definida para este trabalho é composta por 3 camadas: uma primeira camada *embedding* seguida da camada LSTM bidirecional e por fim uma *Dense layer* com a função de ativação *softmax*. Este modelo utiliza a entropia categórica cruzada como função de *loss*, a *accurácia* como métrica e o otimizador *rmsprop*, por ser considerado o otimizador mais rápido em ML [26].

7.2 GRU

A GRU (*Gated recurrent unit*) é também um tipo de RNN semelhante à LSTM, muito usada para desenvolver modelos envolvendo processamento de frases e trabalho com linguagens. Este modelo é mais simples do que a LSTM, o que leva a melhor resultados em alguns casos, exigindo na maioria dos casos um menor esforço computacional [27].

Por estas razões decidiu-se experimentar este tipo de redes neuronais de modo a verificar se se obteria melhores resultados (ou semelhantes à LSTM) numa tentativa de encontrar o melhor modelo. A arquitectura da GRU desenvolvida tem exactamente

a mesma estrutura, métricas, função de *loss* e otimizador que a LSTM, alterando-se apenas a camada bidireccional.

7.3 CNN

A ideia inicial de criar um modelo de previsão usando uma CNN partiu dos conhecimentos adquiridos nas Unidades Curriculares do perfil de Sistemas Inteligentes. No entanto, após alguma pesquisa, percebeu-se que devido ao formato do *dataset* criado, esta poderia não ser a melhor opção. Como após a implementação dos modelos mais recomendados no estado de arte, LSTM e GRU, se obteve resultados bastantes positivos nos dados de validação do *NetLang* (jornais do *Público e Sol*), optou-se por não focar no desenvolvimento nem afinação desta rede, acabando por se desistir da sua utilização.

7.4 Naïve Bayes

Anjaria e Guddeti (2014) [28] [29] realizaram um projeto que culminou no desenvolvimento de um sistema de predição de resultados de eleições com o uso de dados do *Twitter* aliados à mineração de dados e à implementação de um algoritmo de *Naïve Bayes* simples, apresentando resultados muito satisfatórios. Este é um modelo probabilístico supervisionado simples com base na regra de Bayes. Quando aplicado neste contexto, o seu objetivo é estimar a probabilidade de um texto ser positivo ou negativo, tendo em conta o seu conteúdo.

Partindo dos bons resultados demonstrado pelo algoritmo *Naïve Bayes* em trabalhos prévios, procedeu-se a criação deste modelo e fez-se uso da função *MultinomialNB()* presente no ambiente de programação *sklearn*¹ do *Python*.

7.5 Logistic Regression

Um classificador de Regressão Logística, também conhecido como Máxima Entropia, baseia-se num modelo discriminativo que calcula a probabilidade de *y* ocorrer sabendo que *x* ocorre.

Este modelo foi também definido à custa do ambiente de programação *sklearn* do *Python*, fazendo-se uso da função *LogisticRegression* a qual foi aplicado o *solver lbfgs* na otimização.



¹<https://scikit-learn.org/stable/>

Capítulo 8

Resultados obtidos

Neste capítulo serão apresentados e discutidos os resultados obtidos tanto no treino como na validação dos modelos definidos. Serão também avaliados e validados os resultados obtidos com os jornais escolhidos para validação das previsões geradas pelos modelos.

8.1 Modelos

A tabela 8.1 apresenta uma síntese dos resultados obtidos para os diferentes modelos. Facilmente se verifica que o modelo GRU obteve o valor de acurácia mais elevado, atingindo os 92.6 %. Por outro lado, o modelo de *Naive Bayes* apresentou o valor mais baixo, situando-se nos 78%.

Modelo	accuracy
GRU	92.6%
LSTM	91%
Naive Bayes Model	78%
Logistic Regression Model	91%

Tabela 8.1: Síntese dos resultados obtidos na validação dos modelos.

Analisando os gráficos 8.1 e 8.2, referentes à variação de *loss* e acurácia durante o treino dos modelos LSTM e GRU, percebe-se a semelhança dos resultados obtidos pelos dois modelos. No início do treino o valor de *loss* encontrava-se elevado, perto dos 0.7 e após 30 épocas passou a situar-se no intervalo [0.2 , 0.3]. Seguindo o mesmo padrão, o valor de acurácia começou a estabilizar para valores superiores a 90%, a partir da época 5.

A figura 8.3 apresenta a matriz de confusão obtida com o modelo de regressão linear e permite confirmar não só que a acurácia atingida pelo modelo foi de 91% mas também que os valores de precisão e *recall* são bastante positivos. Destaca-se os 97% de precisão obtidos quando a classificação é negativa, o que indica que em praticamente todas as previsões do modelo a avaliação de uma *tweet* com sentimento negativo corresponde efectivamente a um *tweet* classificado no *dataset* como negativo. Por outro lado, apesar do modelo ter identificado 95% de frases Neutras do *dataset*, apenas 84% das classificações *Neutral* estão corretas. Ou seja 16% dos *tweets* foram erradamente classificados como Neutros.

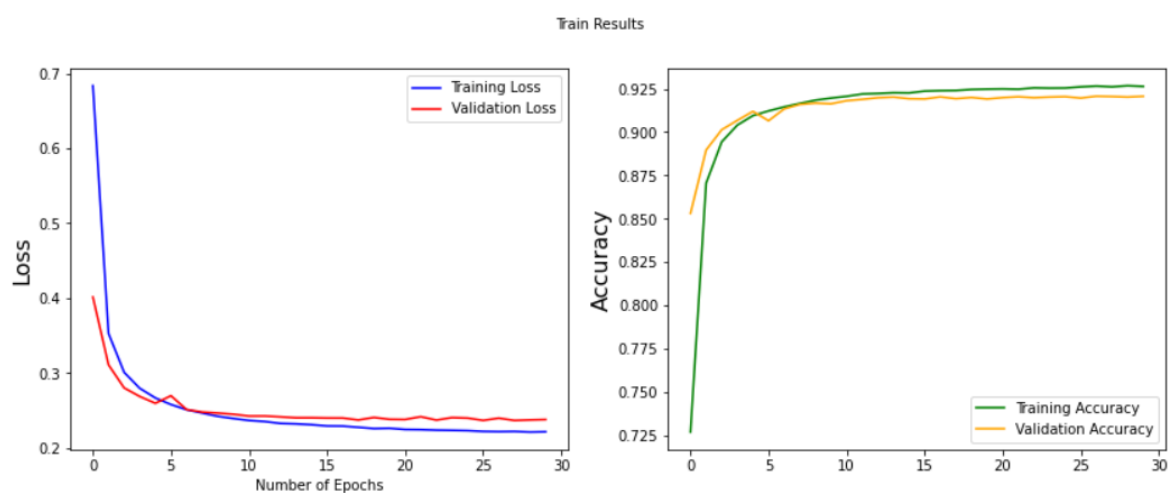


Figura 8.1: Resultados de treino do modelo LSTM ao longo de 30 epochs.




Figura 8.2: Resultados de treino do modelo GRU ao longo de 30 epochs.

	precision	recall	f1-score	support
Negative	0.97	0.89	0.93	12441
Neutral	0.84	0.95	0.89	12226
Positive	0.93	0.89	0.91	12533
accuracy			0.91	37200
macro avg	0.91	0.91	0.91	37200
weighted avg	0.91	0.91	0.91	37200

Figura 8.3: Matriz de confusão obtida para o modelo de regressão linear.

Apesar de todos os modelos criados terem resultados muito positivos, tal como foi visto anteriormente, a GRU destaca-se por ter obtido valores ligeiramente superiores e por isso este foi utilizado como modelo final a integrar na aplicação *Bombedia*.

8.2 Processamento dos jornais

Com o objetivo de validar os resultados, procurou-se estabelecer uma conexão entre os resultados obtidos pelas ferramenta NetAC e BomBedia. Para isso, utilizou-se como ponto de partida notícias do jornal *Sol* e *Público*, previamente extraídas pela coordenadora deste projeto, professora Cristina Araújo. Idealmente, o grupo gostaria de ter utilizado mais jornais para teste, nomeadamente jornais que geram mais controvérsia como o *Correio da Manhã*. Não foi possível obter extrações deste jornal em concreto porque os comentários não estão acessíveis, não possibilitando a sua extração e, consequentemente, a comparação de resultados que se pretendia fazer.

A ferramenta NetAC ¹ está construída assumindo um formato JSON específico para receber a notícia e por isso foi necessário aplicar conversores criados pelos alunos do professor Pedro Rangel Henriques, coordenador do projeto, no âmbito da Unidade Curricular de *Processamento de Linguagem e Compiladores*, para obter as notícias no formato pretendido.

Para poder submeter os ficheiros em formato JSON à ferramenta que continham os metadados e os comentários dos jornais foi apenas necessário aplicar o extrator fornecido para extrair os comentários e depois fazer uma junção aos metadados já obtidos previamente.

8.3 Validação dos resultados com o NetAC

Depois de realizar toda a preparação indicada no tópico anterior, foi possível fazer a análise das notícias na ferramenta NetAC e posteriormente desenvolver um *script* que permitisse, de forma eficiente, submeter todas as notícias ao modelo, extraíndo os resultados. Tendo em conta que em alguns casos o corpo da notícia era muito extenso, optou-se por se avaliar o texto associado ao título concatenado com o subtítulo da notícia, com o objetivo de melhorar a performance da execução do *script*. A tabela 8.4 apresenta parte do documento síntese obtido, em formato pdf, gerado para mostrar, para cada notícia do *Sol*, o seu título, o nº de comentários que possui, a classificação da potencialidade para gerar controvérsia (Sim ou Não), a percentagem de *hate speech* calculada pelo NetAC e a classificação do BomBedia. Realizou-se uma análise semelhante para o jornal *Público* e *Youtube*. As linhas destacadas a cor verde correspondem àquelas que, sob o ponto de vista do grupo, foram correctamente classificadas como Controversas (por possuírem mais de 30 comentários ou uma percentagem de discurso de ódio superior a 1) ou não Controversas (por possuírem menos de 30 comentários ou menos de 1% de hate speech). No anexo B é possível consultar toda a análise efectuada sobre as notícias extraídas para o *Sol*, *Público* e *Youtube*.

É de notar, no entanto, que embora as métricas definidas estejam a ser aplicadas de igual forma às três fontes, é normal que o jornal *Sol*, por exemplo, contenha muito menos comentários associados ao *post* que o *Youtube*. Isto deve-se ao facto de este jornal ter sido criado para apresentar notícias de forma mais objetiva e não tão controversa,

¹<http://netlang-corpus.ilch.uminho.pt:10100/>

como é o caso de jornais como o *Correio da Manhã*. Já no *Youtube*, a movimentação das massas é muito maior e consequentemente, o número de comentários associados a cada vídeo é mais elevado. Assim sendo, é justificável a maior quantidade de notícias mal classificadas pelo modelo para o jornal *Sol*, que se pode verificar no gráfico 8.5.

Table 1: Síntese dos resultados por ficheiro

Título	N de comentários	Controverso	Hate Speech(%)	Resultado Bombedia
Esta solteira? Multimilionário britânico procura mulher para construir família e passar férias de luxo	12	nao	1,4433	Neutral
Manuel Luis Goucha escreve carta aberta ao pai	8	nao	2,1672	Neutral
Marido de Goucha deixa provocação a Joacine Katar Moreira: 'Sera que é xenofobia?'	24	nao	1,5421	Neutral
Ele não está na TVI e não estará mais. Marido de Goucha expulso da estação de Queluz de Baixo	22	nao	1,6746	Neutral
Marido de Goucha indignado com alojamento de migrantes em Lisboa: 'Portugueses sem-abrigo vagueiam ao frio'	40	sim	0,5739	Positive
Manuel Luis Goucha defende Judite Sousa: 'Tenho vergonha de seres humanos assim'	20	sim	0,0	Negative
Goucha comenta piada do marido: 'Nem eu resisto a um arroz de pato ou a uma canja de pombo'	10	nao	0,0	Neutral
Manuel Luis Goucha brinca com telefonema de Marcelo a Cristina Ferreira	3	nao	0,0	Neutral
Claudio Ramos responde a marido de Goucha: 'Tenho 46 anos, uma filha para criar e uma carreira maior que a tua, Rui'	28	nao	0,7989	Neutral
Manuel Luis Goucha passa fim de semana na Holanda para assistir a provas de equitação	16	sim	1,9608	Negative

Figura 8.4: Tabela síntese com os resultados obtidos para o jornal *Sol*

O gráfico 8.5 mostra que:

- Para o jornal *Sol* foram avaliadas cento e noventa e duas notícias. Do total das notícias avaliadas para este jornal, o modelo realizou uma previsão correta em 145 e falhou em 45.
- No jornal *Público* avaliaram-se 122 *posts*. O modelo errou a previsão em apenas 18 textos.
- Por fim, para os noventa e nove títulos de vídeos do *Youtube* analisados, o modelo classificou correctamente 81 títulos.

Os resultados permitem concluir que o modelo apresenta uma boa capacidade de deteção da presença ou não de controvérsia associado a um texto, possuindo maior dificuldade ao decidir se a controvérsia gerada é positiva ou negativa, o que leva aos erros obtidos.

Estes erros encontram-se essencialmente associados a textos cuja a controvérsia é gerada por Personalidades. A título de exemplo, se numa pesquisa no nosso modelo forem incluídas as palavra *Cristina Ferreira*, independentemente do conteúdo do texto, ele será classificado como *Controverso*. No entanto, a frase poderá não estar a fazer referência à apresentadora Cristina Ferreira e sim referir-se a outra pessoa que com ela partilhe o nome. Consideramos que esta falha pode estar relacionada com o facto de a apresentadora se destacar por ser uma das Personalidade Portuguesas com mais seguidores nas suas redes sociais e a quem está associado um elevado fluxo de comentários/*posts* controversos. Acresce ainda o facto de estar constantemente no topo dos assuntos do momento no *Twitter* o que lhe garante muitos *posts* com o seu nome no *dataset* usado para treino do modelo.

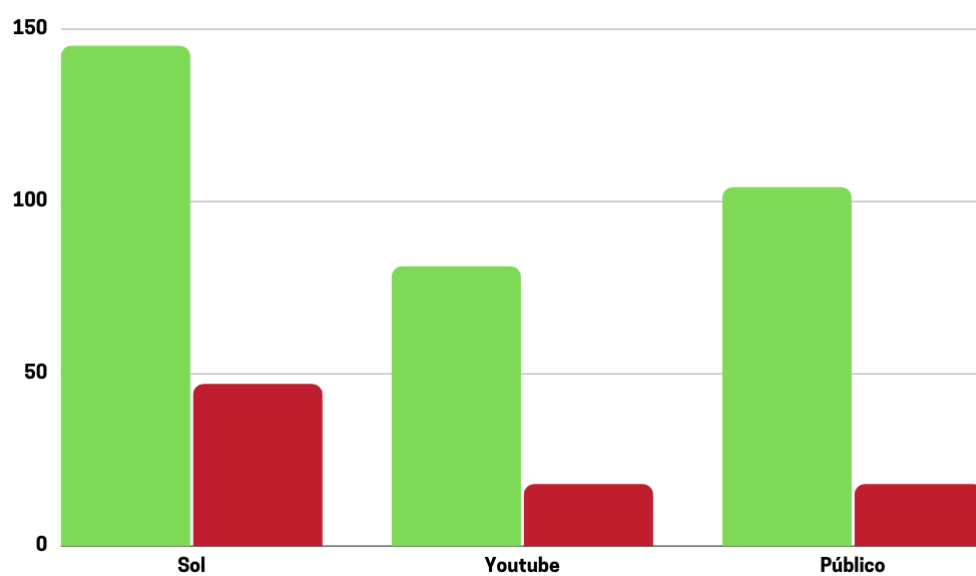


Figura 8.5: Validação dos resultados obtidos pela ferramenta NetAc.

Capítulo 9

Bombastic Media – *Web App*

Concluídas as fases de desenvolvimento e avaliação dos modelos preditivos, passamos agora a explicar, em detalhe, a aplicação *web* que foi desenvolvida para integrar a ferramenta descrita anteriormente. Ao longo deste capítulo, começaremos por enumerar os requisitos estabelecidos pelo grupo para a aplicação, passando à explicação da arquitetura desenvolvida para a criação da *web app* e, por fim, a apresentar a aplicação em si.

9.1 Requisitos da *Web App*

De forma a pensar na arquitetura que iria ser desenvolvida e os passos que seriam precisos seguir para obter a aplicação pretendida, começou-se por elaborar uma lista de requisitos inicial para a aplicação. O grupo estabeleceu as seguintes metas para a *Web App*:

- Possibilidade de autenticação para que os utilizadores tenham a oportunidade de guardar um histórico de *posts* analisados na ferramenta de classificação;
- Integração da ferramenta principal, o analisador, que seja capaz de obter a classificação de *post*, recorrendo ao modelo final desenvolvido;

Após inicializar o processo de desenvolvimento da aplicação, foram definidos mais requisitos, por se ter considerado serem importantes para uma melhor utilização da *app*.

- Uma funcionalidade que permita, dada uma palavra, obter palavras positivas ou negativas associadas a essa palavra.
- Integração de dados fornecidos pelo *Google Trends* de modo a que os utilizadores possam saber quais os temas ”mais quentes” actualmente.

9.2 Público Alvo (Utilizadores)

A aplicação foi desenhada tendo em conta um público-alvo específico. Pretende-se que os utilizadores principais da aplicação sejam os que se apresentam listados a seguir, embora não estejam restritos a estes:

- Pessoas na área de estudo de Ciências Sociais relacionadas com CMC;
- Imprensa nacional que pretenda avaliar a capacidade de uma notícia gerar ou não controvérsia antes de ser publicada;
- Os próprios criadores dos *posts*.

Tendo em conta o público alvo definido, optou-se por utilizar um *design* gráfico simples e intuitivo, de modo a facilitar a interação com a plataforma.

9.3 Arquitetura

A arquitetura desenvolvida para a aplicação *Web* é orientada aos microserviços, possuindo 5 servidores. A figura 9.1 apresenta a arquitetura desenvolvida que será explicada em detalhe de seguida.

- Servidor de autenticação
- Servidor da API
- Servidor da APP
- Servidor de Flask
- *Tensorflow Serving*

A arquitetura foi pensada desta forma por dois grandes motivos:

- O facto de o grupo já ter desenvolvido uma aplicação com esta estrutura no passado, pelo que foi fácil adaptar para os requisitos deste projeto.
- A necessidade de incorporação de código Python e do *TensorFlow* não deveria diminuir a performance do tempo de resposta da aplicação pelo que seria uma vantagem manter cada um num microserviço.

Os pontos listados anteriormente motivaram, consequentemente, a escolha das tecnologias utilizadas.




Figura 9.1: Arquitetura da Web App Bombedia.

9.3.1 App Server

O servidor da aplicação é o servidor principal e contém todo o *frontend* responsável pela interação com o utilizador. Foi desenvolvido em *NodeJS*.

9.3.2 API Server

O *API Server* é responsável por suportar os pedidos feitos à API para obter o histórico dos ficheiros classificados a pedido de um determinado utilizador. Este servidor está conetactado a uma base de dados em *Mongo*.

9.3.3 Authentication Server

Este servidor, também desenvolvido em *NodeJS*, permite que os utilizadores da plataforma se possa autenticar de forma a poderem guardar um histórico dos *posts* que forem classificados a pedido dos mesmos. Sendo assim, o *Auth server* possui uma conexão a uma base de dados em *Mongo* que guardar as informações referentes a cada utilizador. Aquando da autenticação, este devolve um *JSON Web Token* ao servidor da aplicação (*app server*) de forma a que as rotas sejam autenticadas.

9.3.4 TensorFlow Serving

Para obter as previsões dos modelos, desenvolveu-se inicialmente um *script* em *Python* que importava o *TensorFlow* para poder utilizar o modelo e fazer as previsões. No entanto, percebeu-se que esta solução era extremamente ineficiente. Sempre que se corria este *script* para fazer uma previsão, a inicialização do *TensorFlow* demorava muito tempo, fazendo com que a resposta ao pedido no *site* demorasse cerca de 10 segundos. Assim sendo, foi necessário procurar uma solução para resolver este problema.

Optou-se por utilizar o *TensorFlow Serving*.

O *TensorFlow Serving* é um sistema flexível e de alto desempenho para servir modelos de ML, concebido para ambientes de produção. Este mantém a mesma arquitectura de servidores e APIs. Pensado para a integração com o *TensorFlow*, pode ser alargado para servir outros tipos de modelos. [21].

9.3.5 Servidor *Flask*

Uma vez que foi necessário correr os modelos de ML na plataforma *web* e estes estão implementados em *Python*, decidimos exportar a sua utilização para um microserviço em *Flask*, conectando o mesmo à plataforma.

9.4 Aplicação Final

Vamos agora passar à apresentação da aplicação desenvolvida, que pode ser acedida em: <http://netlang-corpus.ilch.uminho.pt:10200/>. O *design* da plataforma foi inspirado no *Smash Lite Template* de *UIdeck* ¹.

9.4.1 Analisador

A funcionalidade principal da aplicação é o analisador. Este analisador consiste num formulário que recebe um texto de CMC e devolve o resultado da previsão do modelo para a capacidade que o *input* passado tem para gerar controvérsia.

Para obter esta classificação adotou-se o seguinte processo: ao receber um texto como *input*, faz-se uma primeira verificação para averiguar se este contém termos que estejam incluídos nos termos mais procurados nos últimos 3 dias (usando para isso os dados do *Google Trends*²). Caso contenha, então é considerado **controverso** e é passado pelo *NRC* para verificar se o sentimento associado é **positivo** ou **negativo**, que indica se os comentários serão maioritariamente a favor ou contra. Caso não contenha, então é submetido ao modelo de *ML* de forma a obter a previsão. De forma a esquematizar este processo, a figura 9.2 contém a *pipeline* de classificação adotada e que foi agora descrita. Inicialmente não era feita esta pré-classificação utilizando o *Google Trends*, mas decidiu-se implementar este passo para melhorar a *performance* de resposta da aplicação.

A figura 9.3 apresenta a página do *Bombedia* que contém o analisador. O resultado que esta ferramenta retorna pode ser **Controverso** ou **Não Controverso**. No caso de ser considerado controverso, então é retornada também uma de duas classificações: *positivo* ou *negativo*. Esta segunda classificação, como já foi sendo explicada ao longo do relatório permite inferir se os comentários gerados serão a favor ou contra o *post* (sendo neste último caso comentários "tóxicos").

¹<https://onepagelove.com/smash-lite>

²<https://trends.google.pt/trends/>

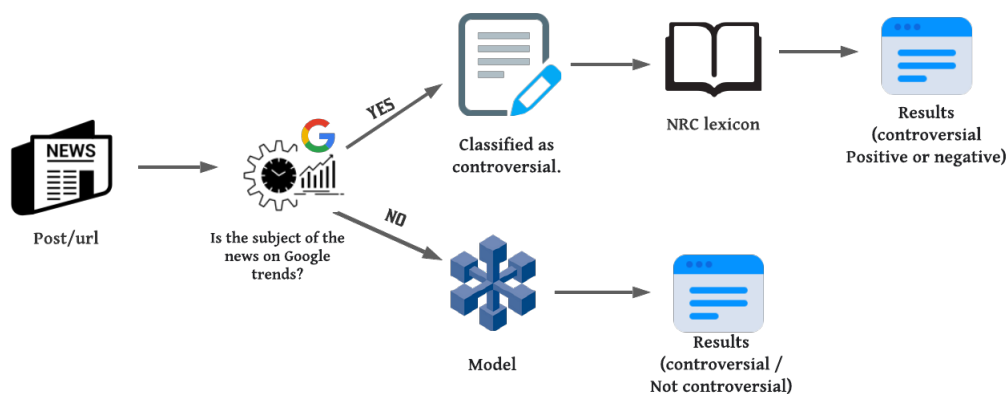


Figura 9.2: *Pipeline* otimizada da classificação de *posts*



Figura 9.3: Analisador de *posts*

Vejamos agora um exemplo de classificação obtida para um *post* em concreto. A figura 9.4 apresenta o resultado obtido para a notícia *Autarca de Borba vai ser julgado por cinco crimes de homicídio* ³. Neste caso, o analisador classifica esta notícia como controversa no sentido negativo, ou seja, "tóxica", com capacidade de gerar comentários negativos.




Figura 9.4: Exemplo de um resultado fornecido pelo analisador

³<https://www.jn.pt/justica/autarca-de-borba-vai-ser-julgado-por-cinco-crimes-de-homicidio-13838733.html>

9.4.2 Analisador por *URL*

Opcionalmente, pode-se analisar um *post* de uma notícia utilizando o *URL* da mesma.

Para implementar este analisador recorreu ao módulo `newspaper` do *Python*. Este módulo permite extrair as várias componentes que compõem uma notícia associada a um determinado *URL*, como o título, os autores, a data, e o texto. Desta forma, é extraído o conteúdo da notícia e passado ao classificador.

Para além disso, o `newspaper` é ainda capaz de reconhecer a língua em que vem escrita a notícia na maioria das vezes, o que é uma vantagem caso se pretenda alargar a ferramenta a mais idiomas.

9.5 Pesquisa por Palavras Controversas

Para além da funcionalidade principal, o analisador, decidiu-se adicionar uma ferramenta que permitisse obter palavras controversas (isto é, associadas a um sentimento positivo ou negativo) a partir de uma determinada palavra que fosse passada como *input*. Assim, pensando no público alvo da aplicação, um utilizador que queira tornar *post* que seja neutro, ou não controverso, num *post* controverso, pode pesquisar por determinados sinónimos que sejam considerados positivos ou negativos conforme o pretendido.

Para implementar esta funcionalidade recorreu-se aos módulos `spacy` e `gensim` (mais concretamente o `word2vec`) do *Python*. Como dicionário utilizou-se o *NRC*. O módulo `word2vec` utiliza uma rede neuronal capaz de associar palavra semanticamente semelhantes. Ao obter uma lista de palavras associadas à palavra passada como *input* bastou depois apenas verificar se estas eram consideradas pelo *NRC* como positivas ou negativas.

A figura 9.5 apresenta a página do Bombedia que contém esta ferramenta.



Figura 9.5: Funcionalidade de procura por palavras controversas no Bombedia

9.6 Temas Quentes

9.6.1 Temas mais procurados

De modo a poder obter uma classificação atualizada no tempo, decidiu-se incorporar os dados fornecidos pelo *Google Trends* na avaliação que é feita, como foi explicado na secção 9.4.1. Para dar ao utilizador a possibilidade de saber quais são os temas mais procurados ou que dão que falar atualmente, decidiu-se incluir na aplicação a funcionalidade que explicaremos de seguida. Através do módulo `pytrends`⁴ do *Python*. Este módulo permite obter dados que são fornecidos pelo *Google Trends* e que permitem saber quais os temas mais procurados no *Google* num determinado intervalo de tempo e localização. Uma vez que, atualmente, este módulo deixou de ter a funcionalidade de extrair dados de um determinado dia sem ser o dia em que se efetua a extração, criou-se um *script* que extrair os dados dos temas mais procurados em cada dia e guarda num ficheiro em formato *csv* de modo a resolver o problema.

Na figura 9.6 é possível observar um excerto da página que possui a funcionalidade descrita. Neste caso apresentam-se os temas mais procurados na região de Portugal para o dia 16 de junho de 2021.



The screenshot shows a web interface with a blue header bar containing the text 'Temas mais procurados'. Below the header is a white box with a date selector labeled 'Selecione uma data:' containing a text input 'dd/mm/yyyy', a calendar icon, and a blue button labeled 'Procurar'. Below this is a table with two columns: 'Ranking' and 'Tópico'.

Ranking	Tópico
1	Britney Spears
2	França-Alemanha
3	Portugal
4	SIC
5	Portugal FC
6	TVI

Figura 9.6: Apresentação dos 6 temas mais procurados no *Google* no dia 16 de junho de 2021

9.6.2 Análise de Temas ao longo do tempo

Para além da saber quais os temas mais procurados diariamente, o *Google Trends* permite também saber qual foi o interesse que determinado tema teve ao longo do tempo. Esta informação também é bastante relevante para a nossa análise, embora não a estejamos a usar diretamente. Seria uma exploração interessante a nível de trabalho futuro.

Neste separador, o utilizador pode introduzir um tema num formulário e é retornado o gráfico que indica o quanto esse termo foi procurado no *Google* ao longo dos últimos cinco anos.

A figura 9.7 apresenta a página do *Bombedia* que apresenta esta funcionalidade e contém um gráfico como exemplo. Este gráfico indica a popularidade que o termo

⁴<https://pypi.org/project/pytrends/>

”coronavírus” teve nas pesquisas do *Google* nos últimos 5 anos, permitindo verificar que este só começa a ser ”quente” no final de 2020. A escala no eixo dos y baseia-se no volume absoluto de pesquisas do termo num dia relativamente ao volume absoluto de pesquisa no *Google* no mesmo dia e estes valores são normalizados para uma escala de 0 a 100.

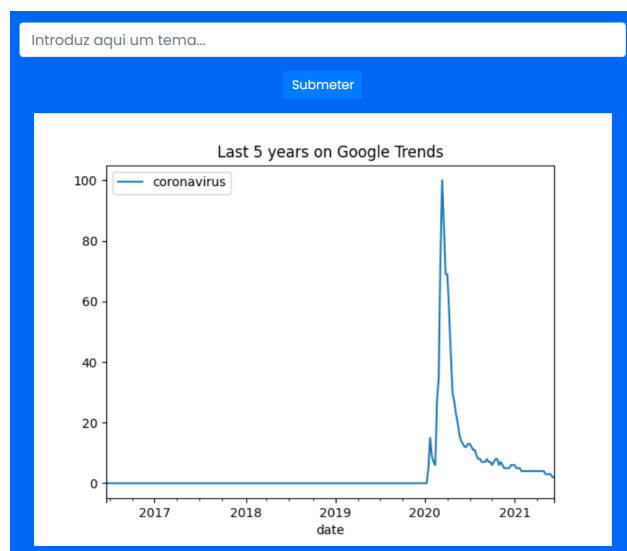


Figura 9.7: Índice de pesquisas para o termo ”Coronavírus” ao longo dos últimos cinco anos

9.7 Manter a classificação atualizada

Um dos problemas futuros deste projeto é a capacidade do modelo fazer previsões atualizadas no tempo. Hoje em dia, a informação navega de um canto ao outro do mundo com muita facilidade e com rapidez, sendo que aquilo que é considerado relevante e controverso hoje pode não o ser amanhã. Nesta subsecção pretende-se explicar de que forma é que este problema foi, pelo menos em parte, resolvido.

Como ferramenta de apoio, decidiu utilizar a API do *Google Trends* de modo a conseguir obter informação sobre os temas mais procurados atualmente. Com esta informação e com a ajuda do *Twint*, foram retirados 100 *tweets* relacionados com o tema mais procurado em cada dia da semana. Após isto, cada um dos *tweets* foi classificado com o mesmo método com que o *dataset* é classificado. Adicionados estes *tweets* ao *dataset* utilizado para treinar o modelo, o novo *dataset* fica então atualizado com os temas mais relevantes ao longo do tempo.

Com o *dataset* já atualizado, basta treinar outra vez o modelo para este poder obter resultados com os novos *tweets* recolhidos. Para a execução deste processo, foi criado um simples *script* que trata de carregar o *dataset*, fazer a preparação de dados necessária e de seguida treinar e guardar o modelo.

Em termos da periodicidade com que é feita esta atualização, o grupo considerou em fazer uma atualização diária com os 5 tópicos mais falados de cada dia. No entanto, tendo em conta que o nosso *dataset* tem por volta de 200 mil entradas, seria necessário incluir, no mínimo, 100 *tweets* de cada tópico, ou seja, o *dataset* aumentaria todos os dias 500 entradas. Ao fim de algum tempo, este processo iria aumentar demasiado

o tamanho do *dataset*. Tendo isto em conta, o grupo decidiu fazer uma atualização semanal, recolhendo *tweets* apenas do tópico mais falado de cada dia da semana. Sendo assim, o *dataset* só aumenta 700 entradas por cada semana, sendo este número mais razoável comparativamente ao anterior.

De modo a tornar este processo automático, decidiu-se criar um *script* para *bash* que trata de correr os ficheiros necessários para atualizar o *dataset* e para o treino do nosso modelo com o *dataset* atualizado. Para além disso, utilizou-se o *Cron* para realizar o agendamento semanal da execução deste script, tornando esta atualização 100% automática.

A figura 9.8 esquematiza, de forma simples, o processo desenvolvido e explicado para a atualização do *dataset*.




Figura 9.8: *Pipeline* do processo de atualização do *dataset*

Capítulo 10

Alternativas, Decisões e Problemas de Implementação

Após a apresentação e descrição das etapas desenvolvidas para obter o produto final, pretende-se, neste capítulo, explicar algumas decisões tomadas que não foram referidas anteriormente. Para além disso, é objetivo desta secção descrever os problemas de implementação que ocorreram assim como refletir sobre as possíveis alternativas para a resolução do projeto. Algumas decisões foram sendo referenciadas ao longo deste relatório, pelo que aqui é feito um resumo destas.

10.1 Decisões

10.1.1 Dataset

Relativamente à escolha do *dataset*, a primeira decisão tomada foi utilizar um *dataset* já avaliado para análise de sentimentos. Esta não foi a melhor decisão pois os *datasets* existentes estão mal classificados, apenas de acordo com os *emojis* que continham. Assim sendo, foi necessário tomar a decisão de descartar este *dataset* e criar, de raiz, um novo, classificado por nós, que levou à obtenção de muito melhores resultados. Para a obtenção do novo *dataset*, os **conselhos** dados pelo Dr. Ricardo Martins foram muito importantes. Este processo permitiu que tivéssemos um maior controlo sobre o que o modelo irá aprender, o que fez com que obtivéssemos melhores resultados. Para treinar os modelos de *Machine Learning* é fundamental que o *dataset* utilizado se encontre bem classificado.

10.1.2 Otimização da classificação do *dataset*

Como foi referido no capítulo 5, decidiu-se otimizar a classificação do *dataset* após se ter constatado que algumas previsões feitas pelo modelo para algumas notícias não estavam a ser bem feitas. Para resolver este problema, criou-se um *corpus* com palavras que, apesar de serem neutras, poderão ser consideradas controversas em determinado contexto. Com esta fase adicional, foi possível obter uma melhor classificação dos *tweets* no que se refere à sua capacidade de gerar controvérsia.

10.1.3 Ferramentas

Em termos de ferramentas, decidiu-se desenvolver o trabalho em *Python* recorrendo ao *TensorFlow* para o desenvolvimento da parte de ML, não só por serem as ferramentas mais utilizadas na área de ML no mundo [30], como também pela familiaridade que o grupo tem com estas ferramentas. No que refere ao desenvolvimento da plataforma *Web*, recorreu-se ao *NodeJs* (com *ExpressJS*) com uma conexão a uma base de dados em *Mongo*. Recorreu-se também ao *Flask* para desenvolver um microserviço responsável por executar o código *Python* que tratava da parte do processamento dos *textos* e integração do *Google Trends*, tornando o processo mais eficiente.

10.1.4 Modelos de *Machine Learning*

Como já foi explicado anteriormente, os modelos que se decidiu utilizar derivaram da pesquisa que foi feita no que se refere ao estado de arte. Este estudo previamente feito mostrou que estes modelos seriam os melhores para o tipo de classificação que se pretendia prever.

10.2 Problemas de Implementação

10.2.1 *Encoding*

No que se refere à criação dos ficheiros em formato JSON das notícias que se pretendia avaliar, obtiveram-se vários problemas de *encoding*. Os ficheiros em formato JSON estavam a ser abertos com "ISO-8859" pelo que os pdfs gerados na ferramenta NetAC estavam a aparecer com os acentos mal apresentados. Para colmatar estes problemas na geração dos pdfs, uma vez que a fonte utilizada no *pdflatex* reconhece um número reduzido de caracteres, passou-se a utilizar o *xelatex* e a garantir que os ficheiros eram em guardados em *UTF-8*. Para converter os ficheiros que não estavam codificados desta forma, utilizou-se o comando:

```
iconv -f CP1250 -t UTF-8 < x.txt > x.utf8.txt
```

Capítulo 11

Conclusão

Este trabalho pretendeu analisar o impacto que determinado texto de *media*, em português, tem nos seus leitores. Para isso foi feita não só uma análise de sentimentos associados ao conteúdo do texto mas também um confronto desse mesmo conteúdo com os temas atuais, que são considerados "quentes" ou controversos, de forma a obter uma classificação mais credível e atualizada no tempo. Tendo em conta o objetivo do projeto, achou-se adequado a atribuição do nome **Bombedia** (*Bombastic Media*), que faz alusão à funcionalidade de previsão de controvérsia que os *posts* de *media* poderão ou não gerar.

Foi criado um *dataset* e classificado de forma a treinar vários modelos de *Machine Learning* para obter um modelo final. A nível de resultados, a *GRU* foi a que obteve melhores valores, tendo sido selecionada como modelo final que iria servir a aplicação *web* desenvolvida. No que se refere à validação dos resultados utilizando notícias de jornais portugueses, pode-se concluir que a classificação obtida é maioritariamente satisfatória, havendo mais classificações incorretas em *posts* que se relacionam com figuras públicas ou temas envolvendo ciganos, homofobia e transgenerismo. Estes últimos temas foram incluídos no *Corpus* definido para otimizar a classificação, o que permitiu colmatar o problema em parte.

Sendo este um projeto de engenharia, o grupo não ficou pela abordagem da Inteligência Artificial para resolver o problema abordado neste projeto e decidiu efetuar uma classificação com recurso ao *Google Trends* para obter os temas que "dão que falar" no momento, efetuando assim uma análise dos *posts* mais eficiente.

A nível de trabalho futuro, várias otimizações poderiam ser feitas. No que se refere à atualização do *dataset*, de modo a este não ficar saturado com temas antigos que já não são considerados reativos atualmente, poderia ser pensada uma forma de retirar estes dados do *dataset*, melhorando a classificação da ferramenta e diminuindo o tempo de execução do próprio modelo. Para além disso, seria necessário garantir também que o *dataset* continuasse balanceado. Outra questão a estudar futuramente seria o tratamento de comentários com ironia uma vez que são difíceis de serem detetados. No entanto, para o contexto de notícias de jornais, esse caso não era tão comum e por isso não chegou a ser explorado neste trabalho. Seria interessante também estudar o impacto dos *emojis* na classificação do *dataset*, uma vez que foi algo que na classificação efetuada se decidiu retirar. A nível da fonte de dados, poderiam ser obtidos dados de outro tipo de CMC, para além do *Twitter*, para enriquecimento do *dataset*. Uma abordagem interessante que poderia vir a complementar a abordagem que é feita atualmente, seria a avaliação de mais metadados de um determinado *post*, como a data e hora de publicação,

os autores, o dia da semana, com inspiração nos artigos analisados no que se refere ao estado de arte.

A nível da definição dos modelos, uma afinação dos hiperparâmetros a utilizar poderia ser feita. No que se refere à língua que foi alvo de estudo, embora o grande foco deste trabalho fosse a análise de textos em português, o projeto foi desenvolvido de forma generalizada de forma a poder ser aplicado a outras línguas, pelo que seria interessante expandir a *web app* para a possibilidade de avaliar *posts* noutras línguas, alargando o âmbito inicial do projeto.

Bibliografia

- [1] Cruz, Luís Braga da (2020), Prediction of toxicity-generating news using machine learning, Faculdade de Engenharia do Porto, <https://repositorio-aberto.up.pt/bitstream/10216/128539/2/412375.pdf>.
- [2] McQuail, Denis (2005). *McQuail's Mass Communication Theory*. SAGE. ISBN 978-1-4129-0372-1
- [3] Thurlow, Crispin; Lengel, Laura; Tomic, Alice (2004). *Computer Mediated Communication*. SAGE. ISBN 978-0-7619-4954-1
- [4] Walther, Joseph B. (1 February 1996). "Computer-Mediated Communication: Impersonal, Interpersonal, and Hyperpersonal Interaction". *Communication Research*. 23 (1): 3–43. doi:10.1177/009365096023001001. S2CID 152119884
- [5] Walther, Joseph B.; Burgoon, Judee K. (1992). "Relational Communication in Computer-Mediated Interaction". *Human Communication Research*. 19 (1): 50–88. doi:10.1111/j.1468-2958.1992.tb00295.x. hdl:10150/185294
- [6] Skovholt, Karianne; Grønning, Anette; Kankaanranta, Anne (1 July 2014). "The Communicative Functions of Emoticons in Workplace E-Mails: :-)". *Journal of Computer-Mediated Communication*. 19 (4): 780–797. doi:10.1111/jcc4.12063
- [7] Garcia, Angela Cora; Jacobs, Jennifer Baker (1 October 1999). "The Eyes of the Beholder: Understanding the Turn-Taking System in Quasi-Synchronous Computer-Mediated Communication". *Research on Language and Social Interaction*. 32 (4): 337–367. doi:10.1207/S15327973rls3204.2
- [8] Herring, Susan (1 June 1999). "Interactional Coherence in CMC". *Journal of Computer-Mediated Communication*. 4 (4). doi:10.1111/j.1083-6101.1999.tb00106.x. S2CID 5070516
- [9] Lisa Branz and Patricia Brockmann. 2018. Sentiment Analysis of Twitter Data: Towards Filtering, Analyzing and Interpreting Social Network Data. In *Proceedings of the 12th ACM International Conference on Distributed and Event-based Systems (DEBS '18)*. Association for Computing Machinery, New York, NY, USA, 238–241. DOI:<https://doi.org/10.1145/3210284.3219769>
- [10] Carvalho, J., Plastino, A. On the evaluation and combination of state-of-the-art features in Twitter sentiment analysis. *Artif Intell Rev* 54, 1887–1936 (2021). <https://doi.org/10.1007/s10462-020-09895-6>

- [11] Z. Jianqiang, G. Xiaolin and Z. Xuejun, "Deep Convolution Neural Networks for Twitter Sentiment Analysis," in IEEE Access, vol. 6, pp. 23253-23260, 2018, doi: 10.1109/ACCESS.2017.2776930.
- [12] Gambino OJ, Calvo H. Predicting emotional reactions to news articles in social networks. Comput Speech Lang. 2019;58:280–303.
- [13] He, Lihong & Shen, Chen & Mukherjee, Arjun & Vucetic, Slobodan & Dragut, Eduard. (2020). Cannot Predict Comment Volume of a News Article before (a few) Users Read It.
- [14] W. CHRISTHIE (2015), SENTIMENTALL: Ferramenta para análise de sentimentos em português, Centro Universitário Luterano de Palmas (CEULP/ULBRA)
- [15] DE PELLE, Rogers Prates; MOREIRA, Viviane P. (2017), Offensive Comments in the Brazilian Web: a dataset and baseline results. In: BRAZILIAN WORKSHOP ON SOCIAL NETWORK ANALYSIS AND MINING (BRASNAM), 6. , São Paulo. Anais [...]. Porto Alegre: Sociedade Brasileira de Computação,. ISSN 2595-6094. DOI: <https://doi.org/10.5753/brasnam.2017.3260>.
- [16] Carvalho, C. M. A., Nagano, H., & Barros, A. K. (2017, October). A comparative study for sentiment analysis on election Brazilian news. In Proceedings of the 11th Brazilian Symposium in Information and Human Language Technology (pp. 103-111)
- [17] Martins, Ricardo & Almeida, José & Henriques, Pedro & Novais, Paulo. (2020). Predicting an Election's Outcome Using Sentiment Analysis. 10.1007/978-3-030-45688-7_14.
- [18] Sayce, David. (2020, December 16), The Number of tweets per day in 2020, <https://www.dsayce.com/social-media/tweets-day/>, acedido em: 16 junho de 2021
- [19] Ahlgren, Matt. (2021, March 2021), 50+ TWITTER STATISTICS & FACTS FOR 2020, *Website Hosting Rating*, <https://www.websitehostingrating.com/twitter-statistics/>, acedido em: 16 junho de 2021
- [20] Morikawa, Rei. (2019, June 3), 12 Best Social Media Datasets for Machine Learning, *Lion Bridge*, <https://lionbridge.ai/datasets/12-best-social-media-datasets/>, acedido em: 16 de junho de 2021
- [21] Rawlani, Himanshu. (2018, October 18), *Towards Data Science*, <https://towardsdatascience.com/deploying-keras-models-using-tensorflow-serving-and-flask->, acedido em: 18 de julho de 2021
- [22] Tsagkias, Manos & Weerkamp, Wouter & Rijke, Maarten. (2009). Predicting the volume of comments on online news stories. International Journal of Press-politics - INT J PRESS-POLIT. 1765-1768. 10.1145/1645953.1646225.
- [23] Tsagkias, Manos & Weerkamp, Wouter & Rijke, Maarten. (2010). News Comments: Exploring, Modeling, and Online Prediction. 191-203. 10.1007/978-3-642-12275-0_19.

- [24] Dornel, Benjamin. (2021, February 3), Predicting Online News Popularity (Part 1), *Towards Data Science*, <https://towardsdatascience.com/predicting-online-news-popularity-part-1-aae9a4f7f1a4>, acedido em: 18 de junho de 2021
- [25] Intellipaat Online. (2020, May 28), What is LSTM - Introduction to Long Short Term Memory, <https://intellipaat.com/blog/what-is-lstm/>, acedido em: 16 de junho de 2021
- [26] Bushaev, Vitaly. (2018, September 8), Understanding RMSprop — faster neural network learning, *Towards Data Science*, <https://towardsdatascience.com/understanding-rmsprop-faster-neural-network-learning-62e116fcf29a>, acedido em: 18 de junho de 2021
- [27] Mani, Kaushik. (2019, February 17), GRU's and LSTM's, *Towards Data Science*, <https://towardsdatascience.com/grus-and-lstm-s-741709a9b9b1>, acedido em: 18 de junho de 2021
- [28] M. Anjaria and R. M. R. Guddeti, "Influence factor based opinion mining of Twitter data using supervised learning," 2014 Sixth International Conference on Communication Systems and Networks (COMSNETS), 2014, pp. 1-8, doi: 10.1109/COMSNETS.2014.6734907.
- [29] Anjaria M, Guddeti RMR (2014) A novel sentiment analysis of social networks using supervised learning. *Soc Netw Anal Min* 4(1):1–15
- [30] Choudhury, Ambika. (2019, May 29), <https://analyticsindiamag.com/top-7-python-neural-network-libraries-for-developers/>

Apêndice A

Corpus de Palavras Controversas

corpus.txt

transgênero
transgênero
trans
joacine katar moreira
joacine
katar
moreira
joacine katar
joacine moreira
katar moreira
racismo
racista
lgbti+
lgbti
lgbt
lgbtq
lgbtq+

Apêndice B

Comparação NetAc vs Bombedia

Jornal Sol:

Table 1: Síntese dos resultados por ficheiro

Titulo	N de comentarios	Controverso	Hate Speech(%)	Resultado Bombedia
Esta solteira? Multimilionario britanico procura mulher para construir familia e passar ferias de luxo	12	nao	1,4433	Neutral
Manuel Luis Goucha escreve carta aberta ao pai	8	nao	2,1672	Neutral
Marido de Goucha deixa provocacao a Joacine Katar Moreira: 'Sera que e xenofobia?'	24	nao	1,5421	Neutral
Ele nao esta na TVI e nao estara mais. Marido de Goucha expulso da estacao de Queluz de Baixo	22	nao	1,6746	Neutral
Marido de Goucha indignado com alojamento de migrantes em Lisboa: "Portugueses sem-abrigo vagueiam ao frio"	40	sim	0,5739	Positive
Manuel Luis Goucha defende Judite Sousa: 'Tenho vergonha de seres humanos assim'	20	sim	0,0	Negative
Goucha comenta piada do marido: 'Nem eu resisto a um arroz de pato ou a uma canja de pombo'	10	nao	0,0	Neutral
Manuel Luis Goucha brinca com telefonema de Marcelo a Cristina Ferreira	3	nao	0,0	Neutral
Claudio Ramos responde a marido de Goucha: 'Tenho 46 anos, uma filha para criar e uma carreira maior que a tua, Rui'	28	nao	0,7989	Neutral
Manuel Luis Goucha passa fim de semana na Holanda para assistir a provas de equitacao	16	sim	1,9608	Negative

Telespetador decidiu dizer a Goucha que estava farto dele e o apresentador respondeu a letra	26	sim	1,1881	Negative
Marido de Goucha partilha caricatura para 'atacar' Claudio Ramos: 'Que me desculpem os canideos de que gosto tanto	4	nao	3,8462	Neutral
Manuel Luis Goucha e Maria Cerqueira Gomes apresentam Voce na TV... nus	12	sim	0,0	Negative
Goucha. 'Dizem que Bruno Caetano foi afastado do 'Voce na TV'! Obrigado por me avisarem'	3	nao	4,0	Neutral
Ja o deram como morto. Goucha 'responde' a Cristina Ferreira com convidado surpresa	14	nao	0,3311	Neutral
A proxima temporada do Voce na TV pode nao contar com Manuel Luis Goucha	6	sim	2,027	Negative
Nunca digas adeus, diz Goucha a Cristina Ferreira	10	nao	0,0	Neutral
'O publico continua com as pessoas em quem acredita', diz Goucha	2	nao	0,0	Neutral
'Para mim, o Deus da televisao e o Manuel Luis Goucha'	6	sim	0,0	Negative
Ferias de Cristina Ferreira quase deram vitoria a Manuel Luis Goucha	8	nao	0,0	Neutral
Manuel Luis Goucha conta como assumiu homossexualidade perante a mae	16	nao	0,6006	Neutral
Cristina Ferreira e Manuel Luis Goucha reencontram-se em almoco: 'Nao se falou de televisao'	7	nao	1,0204	Neutral
Maria Cerqueira Gomes assumiu programa sem Goucha e aproximou-se de Cristina Ferreira	21	nao	1,0526	Neutral
'Este ano envelheci 10 anos'. Goucha nao esquece saida de Cristina	5	nao	0,0	Neutral

Goucha revela que fa se mudou dos EUA para o Alentejo por sua causa	6	sim	1,8182	Negative
'Eu nao quero ditadores no meu pais', diz Manuel Luis Goucha	52	sim	0,4237	Negative
Cristina Ferreira derrota Manuel Luis Goucha na estreia do seu programa na SIC	28	nao	0,2033	Neutral
Manuel Luis Goucha confirma 'traicao' de Cristina Ferreira em direto	6	nao	0,8696	Neutral
Manuel Luis Goucha nao acredita nas Aparicoes de Fatima	8	sim	0,7692	Negative
Goucha confessa: 'quis suicidar-me ha muitos anos'	6	nao	0,0	Neutral
Voce na TV. 'Nunca mais vai ser como era'? Goucha responde a seguidora — FOTO	4	sim	0,0	Negative
Manuel Luis Goucha e Cristina Ferreira iniciam programas de forma semelhante	5	nao	0,0	Neutral
Goucha recorre ao Facebook para criticar revista	5	sim	0,0	Negative
Manuel Luis Goucha nao foi discriminado pelos tribunais	9	sim	2,2124	Negative
'A Cristina Ferreira ganha tanto ou mais que eu', diz Goucha	5	nao	0,0	Neutral
Manuel Luis Goucha 'ataca' novo ministro no Facebook	31	sim	0,3633	Negative
Goucha defende concorrente do Masterchef Junior no Facebook	12	nao	0,5076	Neutral
Tera a amizade entre Teresa Guilherme e Manuel Luis Goucha chegado ao fim?	6	nao	0,0	Neutral
Cristina Ferreira quis roubar marido de Manuel Luis Goucha	24	nao	1,129	Neutral
Goucha reage a acusacoes de agressao no Masterchef Junior	7	sim	0,2747	Positive

Goucha fala sobre novo programa. Nao vou andar la no fornicanco	8	nao	0,0	Neutral
'E muito claro na minha vida que eu ja nao quero fazer programas diarios'	26	sim	1,0116	Negative
Manuel Luis Goucha da 1500 a jovem sobrevivente de cancro	10	nao	1,4493	Neutral
Daniel Oliveira recorda momento em que Mario Machado o ameacou de morte — VIDEO	38	sim	0,2412	Positive
Cristina Ferreira poe fim a duvidas sobre a sua amizade com Manuel Luis Goucha	7	nao	1,1111	Neutral
'Odeio touradas e vivo ha 20 anos com um homem que vai ver todas'	13	nao	0,4673	Neutral
Goucha. 'Bruno de Carvalho e um homem perturbado?'	6	sim	0,0	Negative
Confissoes de Verao de Manuel Luis Goucha: 'Nao sou dado a praia'	5	sim	1,0526	Negative
'E tudo a 7!'. A resposta de Goucha a Cristina Ferreira no Instagram	5	nao	0,5102	Neutral
Marinho Pinto chama 'sirigaita' a Cristina Ferreira	11	nao	0,6993	Neutral
Manuel Luis Goucha revela quem e o seu 'sucessor'	12	nao	1,6471	Neutral
Manuel Luis Goucha partilha imagem do quarto de hospital	5	sim	1,4925	Negative
Manuel Luis Goucha ja reagiu a saida de Cristina Ferreira da TVI	22	nao	0,8333	Neutral
Lesao condiciona presenca de Manuel Luis Goucha	4	sim	0,7576	Negative
Cristina Ferreira e Goucha atacados em direto	7	nao	0,3802	Neutral
'Nao esta contente, va para a SIC'. As 'bocas' de Manuel Luis Goucha	13	nao	0,8403	Neutral

Suzana Garcia volta a comentar polemica: 'A minha avo e negra e a minha mae e mulata'	24	sim	3,4351	Positive
'O senhores deixem-se de mariquices ridiculas'	6	sim	2,0134	Negative
'Esta e uma fase em que eu e o Manel precisamos deste silencio'	5	sim	0,0	Negative
Andre Ventura critica mensagem de solidariedade de Costa para Marega: 'Era a esta hipocrisia que me referia'	86	sim	1,7503	Positive
Marega e o racismo em Portugal	19	sim	1,3767	Negative
Atitude de Bento Rodrigues no Primeiro Jornal esta a tornar-se viral nas redes sociais	40	nao	1,2317	Neutral
O Marega foi ao Dubai ser tratado pelo Fisioterapeuta atraves do medicamento infiltrado Meldonium	26	sim	0,7082	Negative
Andre Ventura da a entender que nao ha racismo nos ataques a Marega	81	sim	1,9399	Positive
FCP. Marega abandona campo depois de insultos racistas	35	sim	1,5184	Negative
Marega reage nas redes sociais e ataca o arbitro	26	sim	1,5816	Positive
A fantochada do racismo	104	sim	1,9879	Negative
Moussa Marega. O jogador que fez historia por dizer 'Basta!' ao racismo	24	nao	3,4413	Neutral
Catarina Martins: 'Adepta de Marega me confesso. Racismo nao e opiniao. E crime	33	sim	2,8679	Positive
PSP diz ja ter identificado dez pessoas no caso Marega	71	nao	1,3315	Neutral
Marcelo condena insultos racistas a Marega	73	sim	2,2989	Positive
PSP ja identificou adeptos que dirigiram insultos racistas a Marega	49	sim	1,4146	Negative
Comportamento dos jogadores do FC Porto 'foi nojento'	34	nao	0,8705	Neutral

Joao Mario sobre o caso Marega: 'Fala-se muito e nao se faz nada'	21	nao	2,2417	Neutral
Caso Marega. Conselho de Disciplina abre processo ao Vitoria de Guimaraes	15	sim	1,5385	Negative
Ministro e responsaveis do futebol vao ao Parlamento falar sobre Caso Marega	17	nao	1,8987	Neutral
Hoje em dia falam muito de jogadores como Mbappe, Messi ou CR7 e esquecem-se de Marega	21	nao	0,8547	Neutral
'Mais do que racismo, foi uma prova de estupidez', diz Pinto da Costa sobre caso Marega	38	nao	1,2903	Neutral
Pepe e Marega alvo de processos disciplinares	14	nao	2,8391	Neutral
APCVD abre processo sobre caso Marega para 'averiguar responsabilidades'	10	sim	0,5917	Negative
FC Porto. Marega recupera de lesao na China	6	sim	0,0	Negative
Ruben Amorim defende Marega: 'Esta na hora de passar-se a acao e castigar'	13	nao	1,4535	Neutral
Vitoria SC reage a caso Marega e diz que nao ira 'vestir a pele do lobo' por um problema 'de dimensao nacional'	16	sim	1,5942	Positive
Jose Carlos Malato sobre a eutanasia: 'Espero que as pessoas possam decidir'	20	nao	0,3356	Neutral
No nono aniversario da legalizacao do casamento LGBT em Portugal, Malato deixa sugestao a Camara de Lisboa	6	sim	3,0	Negative
Eutanasia. Malato foi ao Parlamento e partilhou a sua opiniao	13	sim	0,9709	Negative
Jose Carlos Malato: 'Devia ter morrido no ano passado. Nao gosto nada do presente'	18	nao	1,6949	Neutral
Apresentador Jose Carlos Malato operado de urgencia	10	sim	0,5376	Negative

Redes sociais. Nuno Markl segue conselho de Jose Carlos Malato	4	nao	0,0	Neutral
Jose Carlos Malato deixa mensagem sobre homossexualidade nas redes sociais — Foto	31	nao	0,8782	Neutral
Liliana Campos pede desculpa a Jose Carlos Malato apos insinuar que este queria chamar a atencao	8	sim	0,4762	Negative
Malato sofre problema cardAaco	8	sim	0,8032	Positive
Uniao gay ainda nao e permitida nos Casamentos de Santo Antonio	90	nao	1,1825	Neutral
'A minha mae foi proibida de privar comigo porque sou gay'	22	sim	0,3187	Negative
Cara Delevingne assume relacao no mes do orgulho LGBT	3	sim	0,0	Negative
Vaticano reconhece comunidade LGBT pela primeira vez	8	nao	1,3393	Neutral
Bandeira LGBT hasteada na Camara Municipal de Lisboa	23	sim	0,4093	Negative
Associacoes de defesa dos direitos LGBT francesas criticam palavras do papa sobre homossexualidade	18	nao	0,3527	Neutral
Estas sao as melhores cidades LGBT do mundo	11	nao	4,3243	Neutral
Uma bandeira LGBT 'original' em Moscovo — FOTOS	6	sim	1,3699	Negative
Turquia: manifestacao LGBT acaba em confrontos com a policia	10	sim	2,0362	Negative
Marcha do Orgulho Gay nos Acores mobiliza pouco mais de dez pessoas	37	nao	0,8574	Neutral
Marcha LGBT. Centenas de pessoas desfilaram em Lisboa contra a discriminacao	5	sim	0,0	Negative
Escola crista expulsa aluna por usar camisola com arco-iris nas redes sociais	38	nao	0,9371	Neutral

Gay pride. Todo o orgulho em ser o que se e	18	nao	1,7405	Neutral
Por que razao Julianne Moore e um icone gay?	6	nao	2,381	Neutral
Editor de revista LGBT do Bangladesh agredido ate a morte	6	sim	3,7975	Positive
Associacao LGBT pede que insultos homofobicos feitos a Ronaldo sejam investigados	6	nao	3,7975	Neutral
Milhares na marcha LGBT no Porto	3	sim	0,8721	Negative
Seja a familia como for, o importante e haver amor	19	nao	0,3578	Neutral
Activistas querem abrir a primeira escola 'gay' do Reino Unido	8	nao	3,0822	Neutral
Primeira serie LGBT portuguesa comeca a ser filmada quinta-feira	6	sim	1,9737	Negative
'Eu era gay antes de me curar'	25	nao	2,0797	Neutral
Casal homossexual agredido por grupo no Terreiro do Paco	25	sim	1,9093	Negative
Marcha do Orgulho Gay defende direitos de LGBT	13	nao	0,0	Neutral
Futura ministra de Bolsonaro defende que a mulher 'nasceu para ser mae'	39	nao	1,0668	Neutral
Campolide ja tem duas passeadeiras com as cores do arco-iris	22	sim	1,1905	Negative
Brasil nao pode ficar conhecido como paraíso do mundo gay	64	nao	0,8211	Neutral
Barreiro. Deputadas do Bloco apresentam queixa contra deputado do PSD	25	sim	0,5708	Positive
Lisboa vai ter passeadeiras com cores da bandeira LGBTI contra a homofobia	64	sim	1,0645	Negative
Ricardo Araujo Pereira criticado por declaracoes feitas ao i [video]	12	sim	0,8696	Negative
Malta introduziu o divorcio ha seis anos. Agora prepara-se para o casamento gay	6	nao	0,0	Neutral

Adeptos do FC Porto detidos em Italia por agressao a agentes da autoridade	37	sim	0,2994	Negative
Greta Thunberg podera estar a caminho de Portugal	50	sim	0,3028	Negative
Irma mais nova de Greta Thunberg chama-se Beata e luta pelo feminismo e contra o bullying	15	sim	2,4735	Negative
Mau tempo impede Greta de discursar no Parlamento	71	sim	0,2328	Positive
Greta A(c) louca e perigosa. Acho que ela tem de voltar A escola e calar-se	83	sim	0,5747	Negative
Erro de atriz leva Greta Thunberg a mudar de nome nas redes sociais	13	sim	1,1696	Positive
Depois de ataque de Trump, Michelle Obama deixa mensagem a Greta	63	sim	1,4247	Positive
Greta Thunberg envolvida em polemica com empresa de comboios	14	sim	0,738	Negative
Greta Thunberg esta cada vez mais proxima de Portugal. Agora, em direcao aos Acores	16	sim	0,5848	Negative
Fernando Rocha testa positivo a covid-19 pela sexta vez	21	sim	0,566	Negative
Apos teste negativo, Fernando Rocha volta a testar positivo para covid-19	12	nao	0,0	Neutral
Fernando Rocha revela que esta infetado com covid-19	30	nao	0,2829	Neutral
Apos dois meses em casa, Fernando Rocha revela qual foi a primeira coisa que fez	4	nao	1,0309	Neutral
Ja morreram mais pessoas infetadas com covid-19 no Brasil do que na China	57	sim	0,107	Negative
Bolsonaro visitou padaria e abraçou e tirou fotografias com funcionarios — Video	36	sim	0,5932	Negative
Bolsonaro ameaça ministro da Saude por defender isolamento: Nenhum ministro é indemissível	23	nao	0,4747	Neutral

17 Sou Messias, mas nao faco milagres. Bolsonaro sobre recorde de mortes no Brasil	76	sim	0,467	Positive
Brasil volta a registar recorde de novos casos de infecao por covid-19	14	sim	0,4747	Positive
Bolsonaro protagoniza mais um momento insolito ao ser questionado sobre mortes: Nao sou coveiro	40	sim	0,2681	Positive
O dia mais negro do Brasil	48	sim	0,1741	Positive
O Brasil e dirigido por um fantoche que e absolutamente ignorante, inimputavel, incompetente e cruel	36	sim	0,6923	Positive
Bolsonaro Messias nao faz milagres, nem os seus discipulos o seguem	13	sim	0,7273	Negative
Bolsonaro diz que nao e uma gripezinha que o vai derrubar	60	sim	0,2706	Negative
Brasil. A longa descida ao inferno do Governo de Jair Bolsonaro	33	nao	0,2662	Neutral
Toda a gente morre um dia. Foi assim que Bolsonaro reagiu as 20 mil mortes por covid-19 no pais	87	sim	0,5457	Positive
Fieis de Caminha manifestam-se contra saida de padre motard e sex symbol	38	sim	0,2817	Negative
Padre e falsas freiras escravizavam raparigas em Braga	17	sim	0,7937	Positive
Padre de Pedrogao diz ser um maroto sem maldade	18	sim	0,5272	Positive
Foi um descuido afirma padre apos publicar fotografia em cuecas nas redes sociais	7	nao	0,0	Neutral
Padre encontrado morto na praia de Sao Pedro de Moel	39	sim	0,7194	Negative
Vaticano expulsa padre que revelou homossexualidade	8	sim	0,2551	Negative

Convidada deixa Fatima Lopes estupefacta: A primeira vez que me prostitui foi com um padre	26	sim	0,7547	Negative
Igreja encobriu padre que abusou sexualmente dos filhos	6	sim	0,565	Negative
Crianças forçadas a puxar Porsche do padre — Video	15	sim	0,8351	Negative
Padre expulsa maestro do coro por ser homossexual	21	sim	0,5545	Negative
Padre culpa gays pelos sismos de Italia	10	sim	0,6135	Negative
Padre acusado de burlar o Estado	15	sim	0,3409	Positive
Padre assume homossexualidade no final da missa	28	sim	2,0408	Negative
Igreja: padre denuncia encontros gay em bares e ginásios	5	nao	0,4354	Neutral
Padre gera polémica ao dizer que pedofilia não mata ninguém ao contrário do aborto	29	sim	0,5231	Positive
Detido no Algarve padre que abusou de mais de 20 crianças	13	sim	2,2785	Negative
Ex-padre casa com modelo 55 anos mais novo	6	nao	3,3898	Neutral
Padre de Pedrogão Grande fotografado em roupa interior muda de religião	14	nao	0,3937	Neutral
Cristina Ferreira mostra mais do que queria em fotografia	16	nao	0,0	Neutral
Cristina Ferreira lança livro com nome chocante. Saiba qual	56	nao	0,4115	Neutral
Tens uma relação amorosa com a Cristina Ferreira? Ruben Rua responde	13	nao	2,6316	Neutral
Costa 'despediu' presidente do TdC por telefone	128	nao	0,6305	Neutral
António Costa deseja as melhoras a Trump	14	sim	2,0243	Positive
Donald Trump e Melania testaram positivo para a covid-19	88	sim	0,7235	Negative

António Costa reage a entrevista de Ana Leal ao SOL: aA mentiraa	99	sim	0,4216	Positive
Antonio Costa admite adotar medidas ainda mais restritivas nas proximas semanas	47	nao	0,3435	Neutral
Bazuca de pa3lvora seca desespera UE	32	sim	0,0677	Negative
António Costa diz que manifestaASSAPSo no Porto foi legAtima mas condena arremesso de garrafas	56	sim	0,6382	Positive
António Costa garante que Portugal nAPSo vai usar emprA(c)stimos europeus enquanto situaASSAPSo financeira do paAs nAPSo o permitir	59	nao	0,8277	Neutral
António Costa pede aos portugueses que comprem mAiscaras nacionais	20	nao	0,3311	Neutral
António Costa afirma que o paAs enfrenta gigantesca responsabilidade	27	nao	0,2336	Neutral
António Costa e Fernando Medina na comissAPSo de honra de LuAs Filipe Vieira	119	nao	0,4036	Neutral
Marcelo marca as presidenciais para dia 24 de janeiro	30	sim	0,3929	Negative
Costa elogia comportamento exemplar dos portugueses no fim de semana	44	sim	0,0747	Positive
Comunistas recusam adiar congresso	58	sim	0,8661	Negative
Claudio Ramos revela: aOdiei trabalhar com a Joana Latino	22	nao	1,0309	Neutral
Claudio Ramos confessa a Cristina que lhe custou ficar sem o Big Brother	7	nao	1,4493	Neutral
Claudio Ramos para Carolina Deslandes: EntAPSo burra e quem nAPSo lAa A(c)s tu	15	sim	0,6515	Negative
Emocionado, Goucha revela em que momento se sentiu magoado com Cristina Ferreira	9	nao	1,3699	Neutral
Acusado de discriminaASSAPSo, Manuel LuAs Goucha responde a seguidora	17	sim	2,3891	Positive

Goucha arrasa pessoas que nãPSo cumpriram normas de seguranASSa na NazarA(c): Imbecis e criminosos	33	sim	1,6706	Negative
Rita Blanco dA! que falar apA3s 'indiretas' a Cristina Ferreira: PAue lA! no canal da outra	9	nao	0,5051	Neutral
Cristina Ferreira compra 2,5 Marta Temido considera que votar contra OE A(c) desistir de melhorar os serviASSos pAoblicos de saAode	10	sim	0,0	Negative

Jornal publico:

Table 1: Sintese dos resultados por ficheiro

Titulo	N de comentarios	Controverso	Hate Speech(%)	Resultado Bombedia
Supremo Tribunal Federal do Brasil proibe censura de BD com beijo gay	10	nao	0,3067	Neutral
O PiS tem tudo para ganhar na Polonia, mas a corrida esta mais disputada do que parece	9	sim	1,1682	Positive
Como Tancos salva a direita de si propria	85	sim	0,1044	Negative
Casal sofre agressao homofobica no Terreiro do Paco	53	nao	0,981	Neutral
Arabia Saudita abre-se ao turismo. Ha vistos turisticos pela primeira vez	9	nao	0,0	Neutral
Eles puseram-se Na Pele Dela em nome da igualdade de genero	9	nao	1,105	Neutral
Vamos meter medo no coracao do homem branco e outras citacoes de Robert Mugabe	12	nao	1,3129	Neutral
Anti-gender, uma sombra que cobre a Europa	88	nao	0,5397	Neutral
A diversidade deve comecar na escola? Sim. Caso contrario, vamos continuar a reproduzir estereotipos	15	nao	0,3979	Neutral
Identidade de genero: Estao em causa criancas e jovens que se sentem alvo de chacota	8	nao	0,2053	Neutral
Medicos vao ter guia para atender utentes transgenero e intersexo	13	nao	0,0	Neutral
Parabens insultuosos	16	sim	0,1451	Negative
Esta e a 20a marcha LGBTI+ em Lisboa. Lei mudou, falta a pratica social	42	nao	1,735	Neutral

Milhares levam arco-iris pelas ruas de Lisboa em marcha de orgulho LGBTI+	43	nao	0,3701	Neutral
Investigadoras desmontam conjunto de mentiras sobre ideologia de genero	31	sim	0,6524	Positive
Numa escola em Taiwan, os rapazes vao poder optar pela saia como uniforme	6	nao	1,3636	Neutral
Casamentos de Santo Antonio ainda nao incluem matrimonios gay	15	nao	0,6547	Neutral
Nem sexo, nem morte. Bruno Maia, o medico sem tabus a caminho da AR	5	nao	1,6949	Neutral
EUA proibe embaixadas de hastear bandeiras LGBT	9	sim	1,6667	Negative
Policias recebem formacao para dar resposta a crimes de odio contra pessoas LGBTI	7	sim	1,4388	Positive
De norte a sul do pais, o orgulho LGBTI+ volta a sair a rua	3	nao	0,0	Neutral
Taiwan legaliza casamento entre pessoas do mesmo sexo, uma estreia na Asia	6	nao	0,0	Neutral
Clima social em Portugal ainda e homofobico e transfobico, denuncia ILGA	6	nao	0,0	Neutral
Ser gay e genetico ou deve-se a conjunturas externas ? Colegio retira publicacao de iniciativa do secundario	52	nao	0,458	Neutral
Brunei pede tolerancia com a decisao de punir sexo homossexual com apedrejamento ate a morte	18	nao	0,4695	Neutral
Como o Brasil esta a contracenar com Bolsonaro	7	sim	1,7143	Negative
Fado Bicha: Isto e fado , mesmo que fale do Namorico do Andre e do Chico	23	sim	1,4019	Negative
Uma resposta a Pacheco Pereira: o MeToo e uma revolucao demasiado necessaria e ja vem tarde	15	sim	0,4921	Positive

Lisboa recebe agora a missa Beyonce a pensar na Igreja e nas mulheres negras	6	nao	0,0	Neutral
No Vaticano quanto mais homofobico alguem e, mais hipoteses havera de ser gay	22	nao	1,0989	Neutral
LGBTI nas escolas? Quem esta no terreno dispensa discursos apaixonados	4	sim	0,6116	Negative
Associacoes LGBTI em escolas? Depende muito	86	sim	0,7956	Negative
Jean Wyllys: O que deu a vitoria a Bolsonaro foi a homofobia	126	nao	0,5071	Neutral
PSP identificou dois homens que tentaram atirar ovos contra Jean Wyllys em Coimbra	26	nao	0,1953	Neutral
Primeiro projecto no novo Congresso do Brasil e de "ex-gay" que quer que Biblia seja patrimonio cultural	11	nao	0,5013	Neutral
Homem, mulher ou x? Os passageiros podem escolher a opcao nas companhias aereas	3	sim	2,8986	Negative
Nunca havera um tempo sem Deus ou religiao	29	nao	0,0	Neutral
Transicao social de genero em ambiente escolar atenuar o sofrimento de criancas e jovens	12	nao	0,0	Neutral
Maioria da esquerda reduz poderes de Marcelo, dramatiza Cristas	4	sim	2,4096	Negative
A crise da Direita	5	sim	0,2611	Positive
O genero foi a casa de banho	5	nao	0,0	Neutral
Actor Angelo Rodrigues tera injectado testosterona e foi hospitalizado. Quais os riscos desta hormona?	29	nao	0,0	Neutral
Alerta para cidadaos confusos	23	nao	0,2562	Neutral
Victoria s Secret cancela o desfile anual dos anjos	9	sim	0,0	Negative
E se o seu filho namorasse uma pessoa do mesmo sexo? 42 O CDS e um partido transgenero	19	nao	0,1854	Neutral

Alunos transgenero nao serao mais de 200, adianta secretario de Estado	18	nao	0,6593	Neutral
Inventar uma casa de emergencia para vitimas de violencia domestica LGBTI	5	nao	1,4423	Neutral
A culpa e a reparacao	22	nao	0,5305	Neutral
Primeiro projecto no novo Congresso do Brasil e de 'ex-gay' que quer que Biblia seja patrimonio cultural	11	nao	0,5013	Neutral
Cristina Ferreira a Presidente? Apresentadora nao descarta candidatar-se a Belem	45	sim	0,4902	Negative
Credito Agricola vendeu imovel a mae de gestor da equipa de Licinio Pina	20	nao	0,2545	Neutral
Cristina Ferreira troca TVI pela SIC e vai ocupar as manhas	23	nao	0,9098	Neutral
E o fim de uma era. SIC ultrapassa TVI nas audiencias mensais pela primeira vez em mais de 12 anos	45	nao	0,3008	Neutral
Joacine Katar Moreira recusa paternalismo dos deputados	25	sim	0,6639	Positive
Joacine Katar Moreira exige 'respeito' por parte dos jornalistas	22	nao	0,5859	Neutral
Joacine Katar Moreira: 'Fui eu que ganhei as eleicoes sozinha'	67	nao	0,6008	Neutral
'Irei manter todas as minhas funcoes, a mensagem ira ser compreendida', diz Joacine Katar Moreira	39	nao	0,7386	Neutral
Joacine Katar Moreira vs. Daniel Oliveira: polemica acesa nas redes sociais	72	sim	0,5908	Negative
Joacine Katar Moreira: 'Sem igualdade nao ha liberdade nenhuma'	164	nao	0,6828	Neutral
Livre elege Joacine Katar Moreira, uma activista negra	44	nao	0,9528	Neutral

Joacine Katar Moreira: uma activista negra a caminho do Parlamento?	27	nao	1,625	Neutral
Confronto sobre de tom: direcção do Livre desmente deputada Joacine Moreira	18	nao	0,0	Neutral
Os gritos de 'mentira' de Joacine: 'Senti a vergonha alheia'	18	nao	0,4323	Neutral
Livre preocupado com a sua deputada. Joacine Moreira diz-se apanhada de surpresa	99	nao	0,4457	Neutral
Joacine admite fazer 'cedências necessárias'. Direcção do Livre diz que será preciso 'milagre'	35	sim	0,7225	Negative
Nova direcção do Livre sem Joacine eleita com 95 votos a favor e 15 brancos	17	nao	0,8565	Neutral
O direito de resposta (mais moderado) que Joacine entregou ao congresso	5	sim	1,9481	Negative
Congresso adia decisão sobre retirada da confiança política a Joacine	39	sim	0,0	Negative
Joacine: Elegeram uma mulher negra que gagueja e deu jeito para a subvenção	137	sim	1,2164	Positive
Renunciar ao mandato de deputada? Joacine diz que 'está fora de questão'	17	sim	0,3513	Positive
O que acontece a Joacine se o Livre aprovar retirada de confiança política?	21	sim	0,2088	Positive
Orcamento foi a gota de água que levou Livre a propor retirada de confiança a Joacine	88	nao	0,0872	Neutral
Peco desculpa: Joacine e o Livre discordam em que?	59	nao	0,8722	Neutral
Escolta a Joacine na AR: GNR só pode intervir se estiver em causa a 'segurança física' de deputados	29	nao	0,1907	Neutral
Joacine perdeu a graça	25	nao	0,4008	Neutral
Assessor de Joacine queixa-se de interrupções permanentes, cerco e mercantilização da informação	31	nao	0,189	Neutral

Joacine garante que tensoes nao sao por divergencias programaticas	29	nao	0,578	Neutral
O erro da escolha de Joacine pelo Livre	43	nao	0,5729	Neutral
Joacine diz que votou 'contra ela propria' e devolve responsabilidades da abstencao a direccao do Livre	51	nao	0,5141	Neutral
Polemica entre Joacine e Livre nao acaba aqui. Caso segue para conselho de jurisdicao	54	nao	0,9667	Neutral
Joacine e direccao do Livre trocam acusacoes. Fundador Rui Tavares critica deputada	28	sim	0,2364	Negative
Queixa ou carta aberta: Mulheres Socialistas repudiam programas da SIC e TVI	15	sim	0,2525	Negative
Estao os concursos da SIC e da TVI a reproduzir estereotipos femininos?	21	nao	0,6526	Neutral
Rui Pinto assume ser o denunciante do Luanda Leaks	71	sim	0,1076	Positive
BE quer Isabel dos Santos impedida de vender participacoes compradas com dinheiro roubado	28	sim	0,1938	Negative
Miguel Relvas rejeita ter ligacoes a Isabel dos Santos. BE corrige acusacao, mas mantem suspeita	10	sim	0,2326	Negative
Isabel dos Santos constituída arguida em Angola	48	sim	0,3806	Positive
Isabel dos Santos muda de estrategia e negocia devolucao de dinheiro a Angola, noticia o Expresso	21	sim	0,0	Negative
Advogado de Isabel dos Santos continua inscrito na Ordem, apesar de ter anunciado suspensao	9	nao	0,0	Neutral
Advogados portugueses cobram a offshore de Isabel dos Santos decreto presidencial do pai	25	nao	0,4334	Neutral
Isabel dos Santos: como e que ela construiu um imperio	35	nao	0,2259	Neutral

Isabel dos Santos tera transferido 115 milhoes da Sonangol para o Dubai	46	nao	0,249	Neutral
Isabel dos Santos admite candidatar-se a presidencia de Angola	35	nao	0,4092	Neutral
Isabel dos Santos Presidente de Angola? Que em 2027 possa ser candidata e uma ideia	5	sim	1,2121	Negative
Lava que se farta! : Isabel dos Santos perde processo contra Ana Gomes	52	sim	0,365	Negative
Conan Osiris ja ganhou o Festival da Cancao?	19	sim	0,3947	Negative
Parem de pedir ao Conan para nao ir a Telavive	50	sim	0,2051	Negative
Conan Osiris vence Festival da Cancao	15	nao	0,0	Neutral
Isabel dos Santos: a empresaria, a princesa, o imperio e 'os pes de barro do pai'	19	nao	0,2732	Neutral
Isabel dos Santos diz que servicos de seguranca angolanos lhe entraram nos computadores em Portugal	8	sim	0,0	Positive
Divididos, Joacine e Livre ja estao de olhos postos no futuro	19	nao	0,6908	Neutral
Joacine Katar Moreira: Vamos continuar a trabalhar com a confianca de uns e sem a confianca de outros	93	sim	0,9954	Negative
Livre convocou Joacine para reuniao, mas deputada diz que nao recebeu nada	27	nao	0,7625	Neutral
PS condena declaracoes xenofobas de Andre Ventura sobre Joacine Katar Moreira	18	nao	0,6631	Neutral
Andre Ventura propoe que Joacine seja devolvida ao seu pais de origem . Livre acusa-o de racismo	240	sim	0,9147	Negative
Ventura levado ao colo	142	nao	0,3693	Neutral
Assessor de Joacine retira confianca politica ao Livre	9	sim	1,2121	Negative

Livre aprova retirada de confiança política a Joacine por maioria	147	sim	0,5434	Negative
Joacine deixa de representar o Livre e passa a deputada não-inscrita a partir de hoje	50	nao	1,0436	Neutral
As duas pestes de 2020: coronavírus e racismo	27	sim	0,7448	Positive
Partidos não vão condenar racismo de Ventura no plenário para não prolongar polémica basta-lhes as palavras de Ferro	31	sim	0,6524	Negative
Anti-racismo. Antifascismo. Anticomunismo	35	sim	1,6488	Negative
Novo director da PSP diz que há tanto racismo na polícia como há na sociedade portuguesa	40	nao	0,9877	Neutral
Centenas marcham em Lisboa contra o racismo e a violência policial	15	sim	1,4286	Negative
Líder das Mulheres Socialistas acusa deputado do Chega de racismo e sexismo	26	sim	1,4472	Negative
Portugal instado a enfrentar racismo contra os ciganos	9	nao	1,8307	Neutral
Até quando haverá racismo contra as mulheres negras em Portugal?	21	sim	1,7488	Positive
Mulher acusa polícia de agressão e racismo. PSP chamou bombeiros e disse que era uma queda	171	sim	0,9481	Positive
Presidente dos conselheiros das comunidades portuguesas demite-se por causa de André Ventura	60	nao	0,2612	Neutral
Secretaria de Estado diz que ciganofobia está no dia-a-dia da sociedade portuguesa	6	nao	0,3289	Neutral
Contas de Isabel dos Santos em Portugal arrestadas a pedido de Angola	24	nao	0,197	Neutral

Youtube:

Table 1: Síntese dos resultados por ficheiro

Titulo	N de comentarios	Controverso	Hate Speech(%)	Resultado Bombedia
O Interrogatorio a Fernanda Cancio Ex Namorada de Jose Socrates - Especial CMTV - 22 Abril 2018	59	nao	0,9921	Neutral
A seguir aos ciganos, Brasileiros sao o maior alvo de descriminacao em Portugal	155	sim	1,4893	Negative
Andre Ventura visita Quinta da Fonte e ignora os ciganos...	319	sim	1,8509	Negative
FAMILIA CIGANA IMPEDIDA DE JANTAR NUM RESTAURANTE	139	nao	1,667	Neutral
Almeirim - Este concelho nao e para ciganos	77	sim	2,4209	Negative
Racismo em Portugal	426	sim	1,9299	Negative
Os Pretos Todos Daqui Para Fora!	451	sim	1,8257	Negative
Tabu Brasil: Mudanca de Sexo (Dublado) - Documentario National Geographic	277	nao	1,3985	Neutral
Mulher faz cirurgia para virar homem	310	sim	1,4461	Positive
Mesquita Nunes desmascarou as mentiras do Bloco e Mariana Mortagua entrou em desespero	108	sim	1,2544	Positive
Maria Capaz entrevista Fernanda Cancio	40	sim	2,0765	Negative
Fernanda Cancio TVI Jornal das 8 12-05-16	7	sim	3,4653	Negative
Mariana Mortagua perde as estribeiras quando Mesquita Nunes compara o Bloco a Marine Le Pen	382	sim	0,5618	Positive
ARABE PORCO E COVARDE BATENDO NA NOIVA	429	sim	1,5164	Positive

Crianças Transgenero DE SUA OPINIAO	333	sim	0,8992	Negative
Voce decidiu ser menina? - Transgenero na infancia (OFICIAL)	10442	nao	0,9384	Neutral
SOU TRANS, MAS A CIRURGIA NAO ME FEZ MAIS MULHER — PAPO KABELO COM KAROL PINHEIRO — Salon Line	1312	sim	1,4085	Negative
O casal transgenero em que o pai deu a luz um menino	211	nao	3,2193	Neutral
A saga de ter um filho transgenero	54	sim	0,793	Negative
Ex-gay que tirou o penis explica por que foi facil se tornar 'homem hetero'	5391	nao	1,6146	Neutral
Domingo Espetacular conta o drama de quem se arrependeu de mudar de sexo	4655	nao	1,0523	Neutral
Menino que mudara de genero e nome faz planos: 'Quero ter marido e 3 filhas'	314	nao	0,7344	Neutral
Profissao Reporter - Transgeneros - 01 08 2018	114	sim	1,385	Negative
Miguel Neto no bairro da Jamaica, Portugal [Webnivel 95]	357	nao	0,7711	Neutral
Em Portugal nao ha racismo, ha racismozinho :: Inferno T4 Ep.5	1125	sim	2,0671	Negative
Racista fala que homem nenhum gosta de Negra.	1367	sim	3,2168	Negative
Mulher e presa em flagrante por racismo.	1572	sim	3,9361	Positive
BALANCO GERAL - Racismo e prisao! PM negro e chamado de macaco	543	sim	4,3715	Positive
Mulher racista pratica atos de racismo contra os Africanos durante a manifestacao	39	sim	2,6114	Positive
Racismo cigano no voce na TV quintino Aires rassita cristina ferreira racista	158	sim	1,9827	Positive
Racismo de ciganos no Lumiar	69	sim	1,8484	Negative
Negra vai em protesto Neonazista e se encontra com membro da Klu Klux Klan [Legendado Portugues]	899	sim	1,9975	Positive

'Se for negro, nao entra': Policia italiana impede refugiados de embarcar em trem para Alemanha	574	sim	1,2255	Positive
Adolf Hitler fala sobre os Judeus e os Aliados.	1163	sim	0,667	Negative
5 Frases de Adolf Hitler	2511	sim	0,5226	Positive
Mulher e presa em flagrante apos usar termos racistas contra gerente de supermercado	3861	sim	4,1268	Positive
O anti-Papa: Governo Bolsonaro quer espionar igrejas catolicas	228	sim	0,9688	Negative
A apresentadora de radio Katie Hopkins humilha protestantes anti-Trump	62	sim	0,5324	Negative
Preconceito contra Pobre!!! Absurdo dos absurdos!!!	147	sim	0,7468	Positive
Comentario RACISTA de Lula.	216	sim	4,2659	Negative
Ciganos portugueses no Brasil	32	sim	1,6293	Negative
bairro sao joao de deus...tarrafal	99	nao	0,8828	Neutral
Desacatos entre CIGANOS e PRETOS 2010 08 28	20	sim	1,0753	Negative
Dois ciganos sao executados na porta de casa no bairro Soledade - BALANCO GERAL	70	nao	2,4062	Neutral
CMTV mostra video do tiroteio em Lisboa	48	sim	2,1088	Negative
Mais uma crianca retirada a familia de etnia cigana	16	sim	2,8205	Negative
Zezinho so estava a fazer uma ganza, levou na boca (Ameixoeira)	1016	sim	1,6603	Negative
Jose Berardo mudou estatutos da associacao a revelia dos credores para defender interesses pessoais	97	nao	0,5004	Neutral
Mariana Mortagua mais uma vez humilhada por Leitaõ Amaro	51	sim	0,5249	Negative
Claudio Ramos PASSA-SE DA CABECA COM COLEGAS EM DIRETO - Junho 2018	104	nao	0,8543	Neutral

Claudio Ramos Arrasa famosos que defenderam Julia Palha	67	sim	0,6757	Negative
Maria Leal hoje aqui so para ti- Voce na TV	220	sim	1,1324	Negative
Maria Leal e o desafio de cultura geral - 5 Para a Meia Noite	300	sim	0,6114	Negative
DENTISTA DROGADA, BEBADA, RACISTA E HOMOFOBICA	12	sim	3,3473	Negative
Maria Leal acusada de roubo Responde e e Arrasada	59	sim	1,9745	Positive
Sergio Henriques Responde a Acusacoes de Maria Leal (Ex Namorada) no Manha CMTV 04.01.2017	70	sim	2,2046	Negative
MARIA LEAL — O AMOR E CEGO...SURDO E DESDENTADO	67	nao	1,3975	Neutral
Briga no autocarro em Portugal com um velho racista	65	sim	3,9568	Positive
Portuguese fights /police fights/ range Portuguese compilation	105	Reati vo	1,6958	Negative
TOUR PELO MEU CORPO TRANS + antes e depois	1831	sim	0,9323	Negative
Mudancas de sexo que ficaram INCRIVEIS	3167	nao	1,9726	Neutral
Racismo entre Portugal e Angola,a 3a guerra mundial vai comecar	658	sim	1,7485	Positive
SIC - Bairros Sociais e violencia em Portugal	33	sim	0,2805	Negative
PORTUGAL FUNDADOR MUNDIAL DO RACISMO E COMERCIO DE ESCRAVO -ANGOLANOS DAM RESPOSTA A PORTUGAL	296	nao	1,3373	Neutral
'Somos negros. Portugal ainda nao da valor como gente'	256	sim	1,0941	Negative
O Racismo em Portugal existe? Como enfrenta lo?	51	sim	0,9989	Negative

Racismo ao vivo em plena televisao portuguesa SIC	14	nao	2,0548	Neutral
Ataque racista dentro de aviao gera criticas a companhia aerea	140	sim	3,7453	Positive
Piruka: 'Nao acho as ganzas o lado negro! Mas nunca dei um risco de coca!'	89	sim	0,5691	Positive
TOY FUMA UM CHARRO NA TVI	217	sim	0,511	Negative
travesti e abusado e deixado na mao	5280	sim	1,0535	Negative
Sensivelmente Idiota - Concorda com o acolhimento de refugiados em Portugal?	379	sim	0,584	Positive
Imigrante brasileiro e contra a vinda de refugiados para Portugal	294	sim	0,6618	Negative
A feia verdade sobre os Refugiados em Portugal	171	sim	0,5094	Negative
Refugiados venezuelanos deixam Roraima e chegam a Sao Paulo	1971	nao	0,4789	Neutral
Refugiados em Portugal	5	sim	3,6036	Negative
Refugiadoganhammai que os Portugueses	7	nao	0,3846	Neutral
'refugiados' fogem de Portugal	18	sim	0,4975	Negative
PNR - CONTRA CHEGADA DE REFUGIADOS A PORTUGAL	152	sim	0,5234	Negative
Refugiados em Portugal	4	sim	0,0	Negative
REFUGIADO EM PORTUGAL	7	sim	0,8333	Negative
'Refugiados' Vs Portugueses (reformados, sem-abrigo, etc)	29	sim	0,3727	Negative
'refugiados' fogem, mas os Portugueses PAGAM regresso	13	sim	0,6006	Negative
refugiado viola Portuguesa	23	sim	1,1096	Negative
Refugiados reconstroem a vida em Portugal	22	sim	0,0	Negative
A questao dos refugiados na Europa	29	sim	0,5476	Negative
O drama dos refugiados sirios e africanos que chegam a Calais, Franca	6	nao	0,0	Neutral

Refugiados em Portugal - Muculmanos, Informacoes, Arabes, Abandono e nova vida	245	sim	0,442	Negative
A crise de refugiados: Amnistia Portugal @RTP1	26	sim	0,2352	Positive
Portugal refugiados a chegar	7	nao	0,7812	Neutral
Em Portugal: 'refugiado' eritreu violou uma mulher sem-abrigo de 67 anos	38	sim	0,6897	Negative
Na Europa, Jean Wyllys esta dizendo que e Refugiado do Brasil.	488	sim	1,1894	Negative
Estes sao os 'refugiados' que a Europa recebe diariamente	193	sim	0,4984	Negative
Muculmanos de segunda geracao estao completamente integrados em Portugal	77	sim	0,5199	Negative
Pedidos de asilo aumentam em Portugal	54	sim	0,927	Negative
Portugueses em Angola vivem bem mas nao gostam dos pretos no pais deles	2928	nao	0,9834	Neutral
NA SOMBRA DO PECADO - As Testemunhas de Jeova no documentario da TV de Portugal	51	sim	0,2237	Positive
Os portugueses sao racista? (xenofobo) (Brazucas em Portugal)	67	sim	0,9893	Negative
COMO AS MULHERES BRASILEIRAS SAO VISTAS EM PORTUGAL?	493	sim	1,0802	Negative